



تشخیص ناهنجاری برای تشخیص خطأ در شبکه‌های اجتماعی بی‌سیم با استفاده از یادگیری ماشین

Llorenç Cerdà-Alabern ^{a,*}, Gabriel Iuhasz ^b, Gabriele Gemmi ^{a,c}^a Universitat Politècnica de Catalunya, Barcelona, Spain^b West University, Timisoara, Romania^c University of Venice Ca' Foscari, Italy

اطلاعات مقاله

چکیده

یادگیری ماشین در سال‌های اخیر توجه روزافزونی را در علوم کامپیوتر به خود جلب کرده و انواع پیشرفت‌های این تکنیک را در شبکه‌های کامپیوتری، توجه کمی به استفاده از یادگیری ماشین (ML) برای تشخیص خطأ داشته است.¹¹ که دلیل اصلی آن کمبود مجموعه داده (dataset) است.¹² این امر ناشی از عدم تعامل اینترنت‌های شبکه برای اشتراک‌گذاری داده‌های مربوط به زیرساخت‌ها و خرایی‌های شبکه خود است.¹³ در این مقاله، ما تلاش می‌کنیم با استفاده از تکنیک‌های تشخیص ناهنجاری، این شکاف را بر کنیم تا رویدادهای خرایی سخت‌افزاری را در شبکه‌های اجتماعی بی‌سیم تشخیص دهیم.¹⁴ برای این منظور، ما از ۴ رویکرد یادگیری ماشین بدون نظرات (unsupervised) استفاده می‌کنیم که بر اساس اصول مقاومتی بنا شده‌اند.¹⁵ میک مجموعه داده از یک شبکه اجتماعی بی‌سیم در حال کار (production) ساخته‌ایم که شامل ویژگی‌های ترافیکی و غیر ترافیکی، مانند بار پردازنده (CPU) و حافظه است.¹⁶ برای تحلیل عددی، ما توانایی رویکردهای مختلف ML را در تشخیص یک خرایی ناخواسته درگاه (gateway) که در طول جمع‌آوری داده رخ داد، بررسی کردیم.¹⁷ نتایج عددی ما نشان می‌دهد که وقتی ویژگی‌های غیر ترافیکی نیز در نظر گرفته می‌شوند، عملکرد همه رویکردهای آزمایش شده در تشخیص خرایی درگاه بهبود می‌یابد.¹⁸ ما می‌بینیم که وقتی به درستی تنظیم شوند، همه روش‌های ML در تشخیص خرایی مؤثر هستند.¹⁹ با این وجود، با استفاده از مزایهای تصمیم‌گیری و سایر تکنیک‌های تحلیلی، ما تفاوت‌های رفتاری قابل توجهی را در میان روش‌های ML مشاهده می‌کنیم.²⁰

مقدمه.

تشخیص ناهنجاری (AD) با هدف شناسایی انحرافات از رفتار مورد انتظار انجام می‌شود.²² ثابت شده است که شناسایی این رفتارهای غیرمعمول، ایزولاری قدرتمند در طبقه گسترده‌ای از علوم کاربردی است.²³ برخی نمونه‌ها شامل تشخیص کلاهبرداری کارت اعتباری، تشخیص پزشکی، فرآیندهای صنعتی و شبکه‌های کامپیوتری است.²⁴ اگرچه روش‌های مختلفی را می‌توان برای AD به کار برد،²⁵ پیشرفت‌های اخیر در روش‌های ML و توانایی آن‌ها در یادگیری از داده‌ها، تعداد پیشنهادات AD با استفاده از تکنیک‌های ML را افزایش داده است.²⁶ یادگیری ماشین از یک مجموعه داده برای پیش‌بینی احتمالی استفاده می‌کند.²⁷ گروهی از نمونه‌های مجموعه داده که به عنوان «مجموعه آموزش» شناخته می‌شوند، برای این روش معرفتی از نمونه‌ها «که مجموعه آمایشی» نامیده می‌شوند، انجام می‌پذیرد.²⁸ در برخی کاربردها، مجموعه آموزش بر جسب‌گذاری شده است.³⁰ به عنوان مثال، در تشخیص نوری کاراکترها، مجموعه آموزش شامل تصاویر و برچسب‌های منتظر با کاراکترهای آن‌هاست.³¹ این مسائل، «یادگیری با نظرات» نامیده می‌شوند.³² در مقابل، در AD معمولاً از یک مجموعه داده بدون برچسب استفاده می‌شود و الگوریتم‌های ML «دون نظرات» نامیده می‌شوند.³³ در AD، مجموعه آموزش صرفاً به عنوان نمایشی از عملیات عادی مورد انتظار استفاده می‌شود و ناهنجاری‌ها با انحراف از رفتار مورد انتظار شناسایی می‌شوند.³⁴

عمدتاً به امنیت، بهویزه تشخیص نفوذ به شبکه، معطوف بوده است.³⁵ در مقابل، ما در این AD در حوزه شبکه‌های کامپیوتری، مقاله‌ای بر روی «تشخیص خطأ» تمرکز می‌کنیم.³⁶ یعنی دیگر از تیازهای انسانی

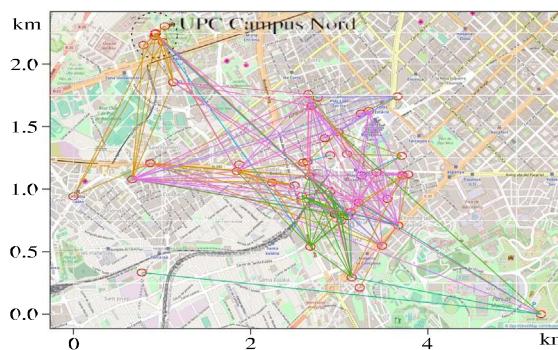
در شبکه‌های کامپیوتری که AD می‌تواند در آن بسیار مورد توجه باشد، اما توجه کمی به آن شده است:

برخی مشکلات، کلارهای اندکی را که می‌توان در ادبیات موضوع در مورد AD برای تشخیص خطأ بافت، توضیح می‌دهند. مشکل اصلی، کمبود مجموعه داده است: دلیل آن این است که یک مجموعه داده واقع‌بینانه برای تشخیص خطأ باید شامل ویژگی‌های مرتبط با ترافیک شبکه و معیارهای سخت‌افزاری، مانند بار پردازنده و استفاده از حافظه باشد.⁴⁰ تولید این نوع مجموعه داده از طریق شبیه‌سازی دشوار خواهد بود، بلکه باید از یک بستر آزمایشی واقعی با در حالت ایده‌آل، از یک شبکه در حال کار به دست آید.⁴¹ با این حال، به دلایل محروم‌گی، اپراتورهای شبکه تجاری این نوع مجموعه داده را از شبکه‌های خود عمومی نمی‌کنند.⁴²

بنابراین، هدف دیگر کار ما ایجاد یک مجموعه داده با داده‌های واقعی است.⁴³ برای انجام این کار، ما بر روی AD در شبکه‌های اجتماعی بی‌سیم (WCN) تمرکز خواهیم کرد.⁴⁴ شبکه‌سازی اجتماعی، که به عنوان شبکه‌سازی از پایین به بالا نیز شناخته می‌شود، مدلی است که از تیاز به دسترسی گستردۀ به اینترنت در مناطق محروم، معمولاً مناطق روستایی و کشورهای در حال توسعه، پدید آمده است.⁴⁵ امروزه صدها شبکه اجتماعی وجود دارند که به روش‌های بسیار متنوعی فعالیت می‌کنند.⁴⁶ WCN‌ها شبکه‌های غیرانتفاعی هستند که توسط کاربران خودشان ساخته می‌شوند، معمولاً نانصب آتنن‌های بی‌سیم بر روی سقف خانه‌هایشان.⁴⁷ گاهی اوقات کاربران WCN نه تنها زیرساخت شبکه را می‌سازند، بلکه برای تشکیل ISP‌های خرد (micro ISP) با هم متحد می‌شوند و دسترسی به اینترنت و خدمات داخلی مدیریت شده توسعه جامعه را فراهم می‌کنند.⁴⁸ WCN‌ها شبیه به ارائه‌دهندگان خدمات اینترنت بی‌سیم (WISP) هستند که معمولاً

* Corresponding author.

E-mail address: Lloren.cerd@upc.edu (L. Cerdà-Alabern).



1. توبولوژی GuifiSants. رنگ‌ها نشان‌دهنده لینک‌هایی هستند که در یک کاتال WiFi یکسان پیکربندی شده‌اند و روتورهای بیرونی را نمایش می‌دهند.

کسپوکارهای کوچکی با حاشیه سود کاهش‌یافته هستند و هدف‌شان ارائه اینترنت گسترشده به جامعه خود است.⁵⁰ ماهیت غیرانتقامی و منابع مشترک شبکه‌های اجتماعی معمولاً کاربران آن را برای مشارکت در پروژه‌های تحقیقاتی و فراهم کردن دسترسی به داده‌های زیراکست شبکه خود، پذیری می‌سازد.⁵¹ بنابراین ما هدف ساخت یک مجموعه‌داده از یک شبکه در حال کار، بر روی WCN تمرکز کردیم.⁵² به طور خاص، ما Guifi.net را در نظر گرفتیم.⁵³ یکی از نمونه‌های پرجسته WCN است.⁵⁴ این شبکه در سال ۲۰۰۴ آغاز به کار کرد و در زمان نگارش این مقاله، ۳۶۰۸۶ گره فعال را گزارش می‌دهد.⁵⁵ یک شبکه پیچیده تبدیل شده است که در آن اینچن‌های کاربران خود-تأمین کننده با اپراتورهای شبکه تجاری همزیستی دارند.⁵⁶

در این مقاله، ما یک مجموعه‌داده را که از یک WCN در حال کار که بخشی از Guifi.net است جمع‌آوری کردیم، تحلیل می‌کنیم.⁵⁷ این WCN در محله‌ای از بارسلون، اسپانیا، مستقر شده است و رفتار گره‌ها بسیار تاهمگین است.⁶⁰ گره‌های در حدود ۶۰ گره و جود داشت.⁵⁹ از نظر توبولوژی، یکی از پیوندهای این WCN بسیار پیچیده است.⁶⁰ گره‌های در ساختمان‌های بلندتر و جود دارند که دارای چندین انتن هستند، برخی سکتور و برخی دیگر پارabolik که بیوندهای نقاطه به طرفیت بالا بیاند.⁶¹ این گره‌ها نوعی ستون فقرات (backbone) برنامه‌بازی نشده را تشکیل می‌دهند.⁶² سایر کاربران غیر فنی در این شبکه ای نهایی هستند که از یک انتن واحد ساخته شده‌اند.⁶³ شکل ۱ مکان‌های خفرایرانی گره‌های GuifiSants و تصویری از روتورهای WiFi 802.11n/ac مورد استفاده در یک گره را نشان می‌دهد.⁶⁴ بسته به نوع انتن‌ها، انسداد پیوندها و فاواری‌های WiFi 802.11n/ac مورد استفاده، طرفیت پیوند از چند مگابیت بر ثانیه تا چند صد مگابیت بر ثانیه متغیر است.⁶⁵ پایداری گره‌ها نیز بسیار متغیر است.⁶⁶ به عنوان مثال، کاربرانی هستند که مرتباً نرم‌افزار را به روزرسانی می‌کنند یا اگر اتصال رضایت‌بخش نباشد، گره خود را را اندازی مجدد می‌کنند.⁶⁷ گره‌های ستون فقرات پایدارتر هستند و خرابی با را اندازی مجدد کسری دارند.⁶⁸ از انجایی که این یک شبکه می‌شود، انتقال نسبتاً انعطاف‌پذیر است: حتی اگر گره ستون فقرات از کار بیفتد، پروتکل مسیریابی مسیرهای گره‌های GuifiSants را گرداند.⁶⁹ گره‌های همچنان می‌توانند که اینترنت، که سرویس اصلی معرفی کاربران است، دسترسی داشته باشند.⁷⁰

AD در چنین WCN‌ها به دلیل ماهیت تاهمگن و متعدد آن چالش‌برانگزیر است.⁷¹ با این وجود، ما معتقد‌کردیم که این نه تنها یک مطالعه جالب به خودی خود است، بلکه سنتزیوایهای دیگری مانند شبکه‌های برزگ اینترنت اشیاء بیز ممکن است ویژگی‌های نیز مجموعه‌ای داشته باشند، که به ما امکان می‌دهد برخی از درس‌های آموخته‌شده از تحلیل WCN را تعمیم دهیم.⁷²

اکثر مطالعات AD مربوط با شبکه‌های کامپیوتی، که در ادبیات موضوع یافته می‌شوند، از ویژگی‌های جمع‌آوری شده تولید می‌کنند.⁷³ در مقابل، مجموعه‌داده‌ای که م تولید کردیم نه تنها شامل ترافیک، بلکه شامل ویژگی‌های از هسته لینوکس است که به عنوان مثال، وضعیت پردازندۀ و حافظه را معنکس می‌کند.⁷⁴ چنین ویژگی‌های معمولاً توسعه ایزراگه‌ی نظرات بر شبکه مانند Nagios، Munin و Munin Pro مجموع آوری می‌شوند.⁷⁵ این حال، این اصراراً صرف گرافیک‌های سری زمانی از ویژگی‌های جمع‌آوری شده تولید می‌کند و تحلیل و تفسیر آن‌ها به مدیر شبکه‌ها و گذار می‌شود.⁷⁶ بنابراین ما علاقه‌مندیم بدانیم که ایا گنجاندن این ویژگی‌های اضافی به ویژگی‌های اساسی می‌تواند ترافیک می‌تواند قابلیت AD را افزایش دهد یا خیر.⁷⁶

به طور خلاصه، مشارکت‌های اصلی ما در این مقاله به شرح زیر است:

- ما یک مجموعه‌داده تولید کردیم که مجموعه برزگی از ویژگی‌های مرتبط نه تنها با ترافیک، بلکه با پارامترهای دیگری مانند پردازندۀ و حافظه را جمع‌آوری می‌کند.⁷⁷ این مجموعه‌داده از یک WCN در حال کار جمع‌آوری شده و ما آن را در مخزن عمومی Zendoo در دسترس قرار دادیم.

تا جایی که ما اطلاع داریم، این اولین مجموعه‌داده‌ای است که شامل چنین تنوع غنی از ویژگی‌های په دست آمده از یک شبکه بی‌سیم در حال کار است که در یک مخزن عمومی موجود است.⁷⁹

ما از روش‌های AD با استفاده از این مجموعه‌داده برای انجام تحلیل تشخیص خطأ با استفاده از ۴ رویکرد پادگیری بدون نظارت ML مبتنی بر اصول مختلف استفاده کردیم.⁸⁰ ما عملکرد این روش‌های شناخته شده ML را که برای AD در شبکه‌های بی‌سیم به کار می‌روند و رفتار آن‌ها را تغییر برخی

پارامترهای سیستم، مانند اندازه مجموعه‌داده، بررسی می‌کنیم.⁸¹

ادامه مقاله به این صورت سازمان‌دهی شده است: بخش ۲ برخی از کارهای مرتبط را ارائه می‌دهد.⁸² بخش ۳، ۴، ۵ رویکرد مورد استفاده در این مقاله را خلاصه می‌کند.⁸³ بخش ۳ متدولوژی و ویژگی‌های جمع‌آوری شده در مجموعه‌داده مورد مطالعه را توصیف می‌کند.⁸⁴ بخش ۵ نتایج عددی را ارائه می‌دهد⁸⁵ و بخش ۶ مقاله را به پایان می‌رساند.⁸⁶

کارهای مرتبط 2.

تشخیص ناهنجاری به مسئله یافتن الگوهایی در داده‌ها اشاره دارد که با رفتار مورد انتظار مطابقت ندارند.⁸⁸ در آمار، اغلب از اصطلاح «داده پرت» برای این مفهوم استفاده می‌شود.⁸⁹ اهمیت AD به این دلیل است که ناهنجاری‌ها در داده‌ها ممکن است شناسانده شوند و فنارهای نادرست

حاجیت در ستاریوهای متعدد باشند.⁹⁰ به عنوان مثال، تشخیص کلامه‌داری برای کارت‌های انتباری، بیمه‌ی ما مقاومت‌های بدهادشتی، تشخیص آسیب و غیره.⁹¹ اهمیت این موضوع منجر به تعداد زیادی مقاله، بررسی و حتی کتاب شده است.⁹² به عنوان مثال، بررسی‌های [20, 21]

مزروی گستردگی بر تکنیک‌های تشخیصی ارائه می‌دهند که در حوزه‌های متعدد توسعه یافته‌اند.⁹³

در شبکه‌های کامپیوتی، بیشتر کارهای مربوط به AD به طور سنتی بر روی مسئله امنیت متمرکز بوده‌اند.⁹⁴ در این زمینه، اغلب از اصطلاح

«سیستم تشخیص نفوذ» استفاده می‌شود.⁹⁵IDS امما عموماً از ناهنجاری‌ها در ترافیک شبکه برای تشخیص طبق گستردگی از حملات

امنیتی، مانند حملات محروم‌سازی از سرویس، شناسایی و غیره بهره می‌برند.⁹⁶ پروری بر IDS‌ها پیشنهادی در ایجاد ترافیک شبکه برای تشخیص از حملات

در [7] یافته شد.⁹⁷ در [22] PCA برای انجام تحلیل ساختاری ترافیک شبکه معرفی شد.⁹⁸ پیشنهاد آن‌ها توجه قابل توجهی را برای PCA در اصلاحات در مطالعه [24, 23] اصلاحاتی در تحلیل PCA برای تشخیص چشم‌ها در جریان‌های ترافیکی انجام شده است،

خود جلب کرد.⁹⁹ به عنوان مثال، در [24, 23] اصلاحاتی در تحلیل PCA برای تشخیص ناهنجاری‌های ترافیک شبکه توسعه تعدادی از مطالعات نیز مورد

که به طور بالقوه حملات شبکه را شناسایی می‌کند.¹⁰⁰ PCA برای تشخیص ناهنجاری‌های ترافیک شبکه توسعه تعدادی از مطالعات DoS با استفاده از انتقاد قرار گرفته است.¹⁰¹ در [27] ضعف‌های PCA تحلیل شده و از Commute Distance برای تشخیص حملات PCA با استفاده از اندازه گیری‌های ترافیک را شناسایی می‌کند.¹⁰² در [14] استدلال می‌شود که مشکلات PCA ناشی از نقص در پذیرش آن است و روش‌های مناسبی برای اعمال PCA پیشنهاد می‌شود.¹⁰³

روش‌های ML سایقه طولانی در استفاده برای AD دارند.¹⁰⁴ تا همین اواخر، پیشتر تحقیقات بر روی استفاده از روش‌های ML با نظارت

هرماه با مجموعه‌داده‌ای مصنوعی یا به شدت حاشیه‌نویسی شده انجام می‌شد.¹⁰⁵ اخیراً این روند به سمت استفاده از مجموعه‌داده‌ای واقعی

هرماه را روش‌های بدون نظارت تغییر کرده است.¹⁰⁶ با این حال، مقالات تحقیقاتی زیادی وجود ندارند که هم مقایسه‌ای از روش‌های بدون نظارت و هم یک مجموعه‌داده واقعی در دسترس عموم را داشته باشند.

مروز سیار خوبی از روش‌های بدون نظارت بر روی چندین مجموعه‌داده در [29] اورده شده است.¹⁰⁸ در اینجا ما عملکرد چندین روش

شناخته شده AD مانند k-NN، CBLOF و غیره را می‌پیشیم.¹⁰⁹ تحقیقات مرتبط‌تر شامل برخی از همین روش‌ها در [30] انجام شده

است که در آن نویسنده‌گان چندین تکنیک AD مبتنی بر خوشبندی را بر روی داده‌های ترافیک شبکه مقایسه می‌کنند.¹¹⁰ ا نوع دیگر

روش‌های AD نیز در سیستم‌های مدیریت شبکه با داده‌های شبکه با ابعاد بالا استفاده شده‌اند.¹¹¹

روش‌های مبتنی بر یادگیری عمیق نیز برای AD استفاده می‌شوند. در [32] نویسندهان مژوی جامعه بر روی روش‌های مختلف یادگیری عمیق برای AD شامل روش‌های بدون نظارت ارائه می‌دهند.¹¹³ آن‌ها همچنین به درستی اشاره می‌کنند که «توضیح‌پذیری» یک مسئلهٔ کلیدی است، بهویژه هنگام استفاده از روش‌های AD که به طور سنتی به عنوان مدل‌های جعبه‌سیاه (black-box) در نظر گرفته می‌شوند.¹¹⁴ مسئلهٔ توضیح‌پذیری همچنین در [34] در مورد مدل‌های مختلف یادگیری عمیق، که شامل خودمرمزگارها [35] و خودمرمزگارهای متغیر [36] هستند، مورد بحث قرار گرفته است.¹¹⁵

بیشتر تحقیقات انجام‌شده در مورد روش‌های بدون نظارت برای AD، عمدتاً بر روی تشخیص نفوذ به شبکه متمرکز است.¹¹⁶ [37] یکی از معده‌داران کارهای پافت‌شده در ادبیات موضوع است که در آن AD شبکه با استفاده از ML با یک مجموعه‌داده واقعی بررسی شده است.¹¹⁷ با این حال، در [37] نویسندهان از AD برای مطالعهٔ رفتار ریدیاها TCP جهت بررسی عملکرد یک شبکه سلولی G4 استفاده می‌کنند که سیاریوی کاملاً متفاوتی نسبت به ماست.¹¹⁸

روش‌های مورد استفاده در ادبیات موضوع را می‌توان به چند نوع تقسیم کرد.¹¹⁹ اینها شامل روش‌های مبتنی بر خوشه‌بندی [41–38]، تکنیک‌های مبتنی بر داده پرت [45–42، 37] و تکنیک‌های مبتنی بر محاسبات نرم [46–48] است.¹²⁰ همه روش‌های توصیف شده در اینجا علاوه بر مشکل توضیح‌پذیری که قلّاً ذکر شد، دارای مزایا و معایبی هستند.¹²¹ روش‌های مبتنی بر خوشه‌بندی معمولاً فقط می‌توانند ویژگی‌های پیوسته را مدیریت کنند؛ معیارهای نزدیکی نامناسب بر نزد تخصیص تأثیر منفی می‌گذارد.¹²² بیشتر روش‌های مبتنی بر داده پرت پیچیده هستند و به شدت به پارامترها وابسته‌اند، در حالی که روش‌های مبتنی بر محاسبات نرم معمولاً به مقادیر زیادی داده تاریخی نیاز دارند و مشکل «بیش‌برازش» مدل‌ها مسلماً مستلزم بزرگ‌تری نسبت به روش‌های با نظارت است.¹²³ در اصل، انتخاب اینکه از چه نوع روشی و چه پارامترهای آموزشی استفاده شود، سیار به حوزهٔ مسئلهٔ و داده‌های موجود پستگی دارد.¹²⁴.

رویکردهای مبتنی بر یادگیری ماشین 3.

در بخش بعدی، ما بر روی آزمایش چندین تکنیک ML بدون نظارت برای AD تمرکز خواهیم کرد.¹²⁵ برای تکنیک‌های AD، ML بر اساس نوع روش‌ها و ویژگی‌های داده‌های موجود به چند دسته تقسیم می‌شود.¹²⁶ ساده‌ترین شکل ناهنجاری‌های نقطه‌ای هستند که می‌توانند تنها با یک ویژگی مشخص شوند و تشخیص آن‌ها آسان‌تر است.¹²⁷ انواع دیگر ناهنجاری‌ها پیچیده‌تر هستند اما در نهایت درک سیار عمیق‌تری از عملکردهای درونی یک سیستم و ایا برنامه تحت نظارت ارائه می‌دهند.¹²⁸ این نوع ناهنجاری‌ها در سیستم‌های پیچیده توزیع شده جفرایی‌بیانی سیار رایج هستند.¹³⁰

ناهنجاری‌های زمینه‌ای در مورد سیستم‌های پیچیده سیار جالب هستند.¹³¹ این نوع ناهنجاری‌ها زمانی اتفاق می‌افتد که الگوی خاصی از مقادیر ویژگی‌ها مشاهده می‌شود.¹³² به صورت مجزا، این مقادیر ناهنجار نیستند، اما وقتی در زمینه مشاهده می‌شوند، یک رویداد ناهنجار را نشان می‌دهند.¹³³ این نوع ناهنجاری‌ها می‌توانند نشان دهنده تغییراتی برنامه، خارجی قریب‌الوقوع سخت‌افزار، پیکربندی نادرست نرم‌افزار یا حتی فعالیت مخرب باشند.¹³⁴ آخرین انواع مده ناهنجاری‌ها که مرتبط هستند، ناهنجاری‌های زمانی و ترتیبی هستند که در آن‌ها یک رویداد خاص خارج از ترتیب یا در زمان‌های نادرست رخ می‌دهد.¹³⁵ این نوع ناهنجاری‌ها در سیستم‌هایی که رابطهٔ فضایی‌زمانی قوی بین ویژگی‌ها دارند، سیار مهم هستند، که این مورد در سیستم‌های توزیع شده پویا مانند شبکه‌های مش سیار صادق است.¹³⁶

این واقعیت است که داده‌های باکیفیت و برچسب‌گذاری شده به ندرت AD یک ملاحظه مهم برای اکثر وظایف در دسترس هستند.¹³⁷ علاوه بر این، روش‌هایی با نظارت که بر روی داده‌های برچسب‌گذاری شده آموزش دیده‌اند، قادر به تشخیص رویدادهای ناهنجار جدید یا پیش‌بینی نشده تغوه‌اند بود.¹³⁸ روش‌های بدون نظارت این تحدیدت را ندارند، با این حال، این روش‌ها دارای چندین نقصهٔ ضعف هستند.¹³⁹ اولًا، آنها

در بسیاری از موارد مستعد نزد بالای «مثبت کاذب» هستند.¹⁴⁰ این می‌تواند به دلایل زیادی مانند بیش‌برازش، فضاهای ویژگی بزرگ و غیره باشد.¹⁴¹ ثانیاً، حتی اگر ناهنجاری‌ها تشخیص داده شده باحتیجه چیزی باعث رویداد ناهنجار شده است، پیش‌نمذانداری در مورد اینکه چه نوع ناهنجاری تشخیص داده شده باحتیجه چیزی باعث رویداد ناهنجار شده است، نیستند.¹⁴² در این بخش از مقاله، ما بر روی کاهش برخی از مسائل ارائه شده در اینجا در مورد روش‌های تشخیص بدون نظارت تمرکز خواهیم کرد.¹⁴³ توجه داشته باشید که ما هر انداره‌گیری از مجموعه‌داده را به عنوان «نمونه» ارجاع خواهیم داد.¹⁴⁴ بنابراین، ما از اصطلاحات رویداد ناهنجار، نمونه ناهنجار، نهاده ناهنجاری، به جای یکدیگر استفاده خواهیم کرد.¹⁴⁵

تحلیل مؤلفه‌های اصلی 3.1.

تحلیل مؤلفه‌های اصلی یک متدولوژی استاندارد است که در کنتل فرایند اماری به کار می‌رود.¹⁴⁷ ایده PCA تقریب زدن نمونه‌های n ویژگی با یک تصویر بر روی یک فضای با ابعاد کمتر از n است.¹⁴⁸ PCA به خوبی در ادبیات موضوع مطالعه شده است، بنابراین ما از توصیف این روش صرف‌نظر می‌کنیم و فقط در مورد اماراتی که برای تحلیل خود استفاده کردیم بحث می‌کنیم.¹⁴⁹ خواننده علاقه‌مند می‌تواند برای جزئیات بیشتر به [14] مراجعه کند.¹⁵⁰ به منظور تشخیص ناهنجاری‌های یک امتیاز جدید، چندین شاخص وجود دارد.¹⁵¹ ما در اینجا می‌دانیم که در مطالعه‌ما، بهترین عملکرد مربوط به خطای پیش‌بینی مربع (SPE) است که به عنوان آماره Q نیز شناخته می‌شود:

$$(1) Q_j = \sum_{i=1}^n e_{ji}^2$$

که در آن e_{ji} باقیمانده آن ویژگی‌های نمونه [است].

هنگامی که یک ناهنجاری تشخیص داده می‌شود، به یک سیستم تشخیص برای تعیین علل ریشه‌ای آن نیاز است. رویداد کلی استفاده از «نمودارهای مشارکت» است. ایده چنین نمودارهایی، تخمین مشارکت هر ویژگی مشاهده شده از یک نمونه در یک مقدار اماراتی خاص است که ناهنجار در نظر گرفته شده است. روش‌های مختلفی برای ساخت نمودارهای مشارکت پیشنهاد شده است. در این مقاله، ما از «مشارکت‌های تجزیه کامل» (CDC) استفاده خواهیم کرد. محاسبه CDC آسان است و عملکرد تشخیص خوبی را در یک سیستم نظارت بر شبکه نشان می‌دهد. CDC برای آماره Q که در بالا تعریف شد، توسط [49] داده شده است:

$$(2) CDC^{Q_j} = \sum_i e_{ji}^2.$$

Isolation Forest

در سال‌های اخیر، آشکارسازهای مبتنی بر گروه در مورد AD محبوبیت پیدا کرده‌اند.¹⁶⁵ این روش‌ها خروجی‌های چندین الگوریتم به نام «آشکارسازهای پایه» را ترکیب می‌کنند که سپس برای ایجاد یک خروجی یکپارچه استفاده می‌شوند.¹⁶⁶ این الگوریتم‌ها بر این فرض عمل می‌کنند که برخی الگوریتم‌ها بر روی زیرمجموعه‌ای از داده‌های موجود به خوبی عمل می‌کنند در حالی که برخی دیگر می‌توانند بر روی زیرمجموعه متفاوتی بهتر عمل کنند.¹⁶⁷ از سوی دیگر، ترکیب گروهی اغلب بهتر از برآوردگرهای منفرد عمل می‌کند، به دلیل توانایی آن‌ها در ترکیب خروجی‌های چندین الگوریتم.¹⁶⁸ بیشتر روش‌های گروهی به داده‌های برچسب‌گذاری شده نیاز دارند، با این حال، هم از دیدگاه نظری [51] و هم عملی [52] نشان داده شده است که روش‌های گروهی بدون نظارت ویژگی‌هایی با هم‌تایان با نظارت خود دارند.¹⁶⁹ ما می‌توانیم یک موازنۀ بایاس-واریانس اصلاح شده را برای تنظیم تحلیل ناهنجاری فرموله کنیم [51]. این امر بسیاری از الگوریتم‌هایی با نظارت را قادر می‌سازد تا به وظایف بدون نظارت «تعمیم» یابند.¹⁷⁰ یکی از مسائل کلیدی که نتیجه مستقیم این تعییم است، افزایش دشواری در انتخاب «فراپارامترهای» مناسب است.¹⁷¹

چنگل ایزوولمساری یک الگوریتم مبتنی بر گروه داده پرت است که از چندین «درخت ایزوولمساری» ساخته شده است.¹⁷² این الگوریتم زیرفضاهای تصادفی از داده‌ها را کاوش می‌کند.¹⁷³ در اصل، این الگوریتم زیرفضاهای محلی تصادفی را کاوش می‌کند زیرا هر درخت از تقسیم‌های متفاوتی استفاده می‌کند.¹⁷⁴ امتیازدهی با تعیین اینکه یافتن یک زیرفضای محلی با ابعاد کم که در آن یک رویداد خاص ایزووله شده است چقدر آسان است، انجام می‌شود.¹⁷⁵ به عبارت دیگر، فاصله از برگ تا ریشه به عنوان امتیاز داده پرت استفاده می‌شود.¹⁷⁶ مشابه چنگل تصادفی که یک روش با نظارت است

خودرمزگذارهای متغیر

- در این روش، امتیاز نهایی با میانگین‌گیری از طول مسیر هر نقطه‌ی داده در درخت‌های مختلف ایزوله‌سازی به دست می‌آید. در اغلب ستابریوها، الگوریتم جنگل ایزوله‌سازی بر این فرض عمل می‌کند که شناسایی یا ایزوله‌سازی نقاط پرت در زیرفاضه‌ای با بعد کمتر که از تقسیم‌های تصادفی حاصل شده‌اند، محتمل‌تر است.
- در مرحله‌ی آموزش، جنگل ایزوله‌سازی معادل بدون ناظر درخت‌های تصمیم‌گیری را می‌سازد. این در درخت‌ها دو نوعی هستند و حداقل دارای N گره‌ی برگ می‌باشند که برای تعادل نقاط پرت داده در مجموعه‌ی آموزشی است. بنابراین، گره‌ی ریشه شامل تمام نقاط داده برای پردازش بوده و به عنوان وضعیت اولیه درخت ایزوله‌سازی T در نظر گرفته می‌شود. سپس، یک فهرست کاندیدا C شامل گره‌ی ریشه اولیه می‌شود. از این فهرست، گره‌ای به صورت تصادفی انتخاب می‌شود. سپس یک مقدار مقداردهی اولیه می‌شود. این تقسیم R به صورت $R = R_1 + R_2$ می‌شود. این تقسیم با انتخاب یک مقدار تصادفی از R و پیزگی λ انجام می‌شود، به گونه‌ای که تمام نقاط داده در شرط $x_i \leq a$ را ارضاعی کنند و نقاط در R_2 را. این مقدار a به صورت یکنواخت و تصادفی از بین حداقل و حداکثر مقدار پیزگی λ در گره R انتخاب می‌شود. هر دو مجموعه‌ی R_1 و R_2 به عنوان فرزندان گره R در درخت T در نظر گرفته می‌شوند. اگر هر یک از R_i ها از یک نقطه داشته باشد، به فهرست C افزوده می‌شود؛ در غیر این صورت، آن گره به عنوان برگ تعیین می‌گردد. این فرایند تا زمانی که فهرست C خالی شود، تکرار می‌شود. نتیجه‌ی آموزش، درخت دودویی ناموتانی خواهد بود که در آن، گره‌های مربوط به نقاط پرت عموماً در بعد پایین‌تری نسبت به نقاط اعیادی ایزوله می‌شوند. این رویکرد ذاتاً تصادفی چندین بار تکرار شده و نتایج به صورت میانگین‌گیری ترکیب می‌شوند. پیچیدگی محاسباتی این روش برابر با $O(N \log N)$ است. درخت‌های ایزوله‌سازی خوش‌های سلسه‌مراتبی از داده‌ها ایجاد می‌کنند، اما همان‌طور که در پاراگراف‌های پیشین اشاره شد، به شدت تصادفی هستند. این پیزگی در استفاده از این روش بر روی داده‌های واقعی ممکن است مشکلاتی ایجاد کند. با استفاده از زیرنمونه‌گیری می‌توان عملکرد محاسباتی را بهبود بخشید و به ایجاد تنوع کمک کرد که برای روش‌های ensemble چیزی است. با این حال، تنوع همچنین از طریق فرآیند تصادفی ساخت درخت‌های ایزوله‌سازی حاصل می‌شود، حتی شاید پیشتر از زیرنمونه‌گیری. بنابراین، انتخاب صحیح پیزگی یا پیزگی λ بشدت تحت تأثیر تصادفی بودن قرار دارد. در نتیجه، کاملاً ممکن است که مدل‌هایی با عملکرد ضعیف به دلیل انتخاب نامناسب پیزگی‌ها در مرحله‌ی آموزش ایجاد شوند.

6.1. فاکتور ناهنجاری محلی مبتنی بر خوشبندی

چندین فرض بنیادین در روش‌های بدون ناظر وجود دارد. تکنیک‌های مبتنی بر مجاورت یک رخداد یا نقطه‌ی داده غیرعادی را زمانی تعریف می‌کنند که ناحیه‌ی اطراف آن به طور پراکنده از داده‌ها بر شده باشد. این مفهوم مجاورت را می‌توان به روش‌های مختلفی تعریف کرد.

در روش‌های مبتنی بر خوشبندی عدم عضویت یک رخداد در یک خوشه از طریق فاصله‌ی آن از سایر خوشه‌ها، اندازه‌ی نزدیکترین خوشه، یا ترکیبی از این عوامل سنجیده می‌شود تا امتیاز غیرعادی بدون محاسبه گردد. برخی روش‌ها به شدت بر خوشبندی متنکی هستند، به طوری که اساساً هر چیزی که نتوان به یک خوشه نسبت داد، به عنوان یک ناهنجاری در نظر گرفته می‌شود.

رووش‌های مبتنی بر فاصله امتیاز ناهنجاری را بر اساس فاصله‌ی یک رخداد تا نزدیک ترین همسایگانش تعیین می‌کنند. در این حالت، رخدادهایی که فاصله‌ی زیادی با همسایگان نزدیک خود دارند، به عنوان ناهنجار شناخته می‌شوند. این روش‌ها معمولاً دارای دقت بالاتری هستند، اما این دقت پیشتر با هزینه‌ی محاسباتی بالاتری همراه است.

بر اساس تعداد رخدادهایی که در یک ناحیه‌ی محلی فاصله ای از میانگین می‌باشد، این روش‌های مبتنی بر چگالی تعداد برای تعریف چگالی محلی و محاسبه امتیاز ناهنجاری استفاده می‌شود. برخی روش‌های مبتنی بر چگالی فضای داده را تقسیم‌بندی می‌کنند، در حالی که روش‌های خوشبندی داده‌ها را گروه‌بندی می‌نمایند. عامل پرت محلی مبتنی بر خوشبندی یا CBLOF یک الگوریتم مبتنی بر مجاورت است.

که ترکیبی از عامل پرت محلی (LOF) و یک تکنیک خوشبندی می‌باشد LOF. امتیاز ناهنجاری (یا پرت بدون) را بر اساس چگالی محلی تنظیم می‌کند. چگالی در این روش به صورت معکوس

میانگین فاصله‌ها تعیین می‌شود. این رویکرد باعث می‌شود که رخدادهایی که در نواحی محلی با چگالی بالا قرار دارند، حتی اگر از سایر رخدادهای اطراف خود جدا باشند، امتیاز ناهنجاری بالاتری دریافت کنند. تبلیغ اصلی این

در واقع، CBLOF امتیازی است که در آن ناهنجاری‌ها به عنوان ترکیبی از فاصله‌ی محلی تا خوشه‌های مجاور و اندازه‌ی خوشبندی که هر رخداد بآن تعلق دارد، تعیین می‌شوند. بنابراین، رخدادهایی که در خوشبندی کوچک قرار دارند و فاصله‌ی زیادی با خوشبندی مجاور دارند، به عنوان ناهنجار شناسایی می‌شوند

رمزگذارهای خودبازسازی متغیر یا مدل‌هایی از شبکه‌های عصبی عمیق هستند که برای آموزش بدون ناظر طراحی شده‌اند و می‌توان از آن‌ها در ظایای تشخیص ناهنجاری (AD) استفاده کرد [57, 58]. این مدل‌ها اغلب همراه با رمزگذارهای خودبازسازی معمولی یا (AE) مطرح می‌شوند که آن‌ها نیز مدل‌های یادگیری عمیق با اجزای توبولوژیکی مشابه مانند رمزگار و بازرمزنگار هستند. رمزگذار پنهان می‌کند تا نمایش پایین‌بعدی از داده‌های ورودی را پیامزد مشابه تحلیل مؤلفه‌های اصلی یا (PCA) و بازرمزنگار سعی دارد داده‌های ورودی را در بعد اصلی بازسازی می‌کند AE ها معمولاً ساختاری متقان دارند. هدف AE ها این است که داده‌ها را به گونه‌ای رمزگذاری کنند که خطای بازسازی کاهش یابد. در کاربردهای تشخیص ناهنجاری، خطای بازسازی AE می‌تواند به عنوان امتیاز ناهنجاری مورد استفاده قرار گیرد، مشروط بر اینکه AE داده‌های آموزشی کافی برای دستیابی به حداقل خطای بازسازی برای داده‌های نرمال داشته باشد [59].

در مقابل، VAE ها تلاش می‌کنند داده‌ها را به یک توزیع پنهان چندمتغیره رمزگذاری کنند که سپس توسعه بازرمزنگار مورد استفاده قرار می‌گیرد. تفاوت اصلی بین VAE و AE است که به جای تولید یک بردار پنهان که بازرمزنگار بتواند آن را بازسازی کند، VAE ها دو بردار را می‌آموزند که پارامترهای میانگین و واریانس یک توزیع را نشان می‌دهند؛ ازین توزیع، بردار پنهان نمونه‌گیری شده و توسط تابع بازرمزنگار برای بازسازی ورودی اصلی استفاده می‌شود. بهطور کلی، فضای پنهان تولید شده توسط VAE ها به سمت نرمال بودن گرایش دارد، که پخش محدودی از آن به دلیل منظم‌سازی شدید رمزگذارها از طریق جمله‌ای کوبلک-لایلر (Kullback-Leibler divergence) است.

VAE ها برخی چالش‌های رایج با سایر مدل‌های یادگیری عمیق دارند. اول اینکه آموزش آن‌ها نسبتاً کند است و اغلب راهنمایی سخت افزار تخصصی مانند GPGPU دارد. همچنین، مجموعه‌داده‌های بزرگ نیازمند توبولوژیکی های شبکه‌ای پیچیده هستند. با این حال، استفاده از توبولوژیکی های پیچیده برای مجموعه‌داده‌های کوچک که می‌تواند منجر به بیشتر از شود. یکی از روش‌های منظم‌سازی که در کاهش بیشتر برآورده بوده، افزودن لایه Dropout است [60].

نوعی از VAE با نام β -VAE برای تشخیص ناهنجاری پیشنهاد شده است [61, 62]. این نوع جدید، یک ابریامارت تازه به نام β معرفی می‌کند که طرفیت رمزگذاری گلوگاه پنهان را محدود کرده و نمایش‌های پنهان را به سمت تفکیک پذیری سوق می‌دهد. شایان ذکر است که VAE استاندارد را می‌توان خاصی از این نوع جدید در نظر گرفت، به طوری که زمانی که $\beta = 1$ باشد، این دو معادل هستند.

3.2. Feature selection

مجموعه‌داده‌های نامتوازن با ابعاد بالا یکی از چالش‌های اصلی در حوزه‌ی تحقیقاتی یادگیری ماشین هستند [63]. با استفاده از روش‌هایی که امکان انتخاب دستی یا خودکار زیرمجموعه‌ای مرتبط از مجموعه‌ی اولیه بزرگ و بالقوه تکراری و پیزگی‌ها را فراهم می‌کنند، می‌توان هم دقت و هم سریار محاسباتی روش‌های یادگیری ماشین را بهبود بخشید. مجموعه‌داده‌ای با ابعاد کمتر و تعادل مناسب همچنین می‌تواند بیشتر از قابل توجهی محدود کرد و تفسیر نتایج پیش‌بینی را آسان تر کند [64]. در مورد انتخاب و پیزگی‌های بدون ناظر، نمی‌توان به متغیرهای هدف تکیه کرد، بلکه باید از معیارهای هدف دیگر و خوشبندی برای بهبود دقت تفکیک کرد،

معیار کشیدگی (Kurtosis) را می‌توان برای هر پیزگی به عنوان یک روش انتخاب و پیزگی بدون ناظر محاسبه کرد. کشیدگی و پیزگی λ ، برای $i=1, \dots, n$ می‌شوند، اینتا با نرمال‌سازی نمونه‌ها میانگین صفر و انحراف معیار واحد محاسبه می‌شود:

$$(3) k_{ij} - \mu_i \over \sigma_i, \quad j = 1, \dots, m$$

که در آن m میانگین μ_i نحraf معیار و پیزگی λ هستند، و σ_i نمونه‌ی λ از پیزگی λ است. سپس کشیدگی (Kurtosis) و پیزگی λ به صورت زیر محاسبه می‌شود:

$$(4) K_i = \sum_{j=1}^m k_j^4 \over m$$

کشیدگی عیاری برای "غیر یکنواختی" داده‌هاست. این معیار شکل توزیع احتمال را توصیف می‌کند. مقادیر ایالی کشیدگی معمولاً با درجه‌ی ایالی انحراف انتقال پرت همراه است. اگرچه تفسیر آن سه استهه تنها زمینه‌ی کاربرد متغیر است. در مورد ما، سطح کشیدگی محاسبه شده برای هر پیزگی به ما اجازه می‌دهد

برگهای را انتخاب کنیم که توزیع نسبتاً غیر یکنواختی دارند.

برای توانی با محاسبه کشیدگی بر اساس فاصله های ماهالانوبیس (Mahalanobis) تمام نقاط داده را نظر نمی کنید. کشیدگی چند بعدی را برای توانی با فضای پاسیونی، محدود کنند.

تفاوت مطلق میانگین مطلق (Mean Absolute Difference) تفاوت مطلق از مقدار میانگین را محاسبه می‌کند. امتیاز بالاتر نشان دهنده تاننسیل تمايز بيشتر است [65]. اين معيار به صورت زير تعریف می شود:

$$MAD_i = \frac{1}{m} \sum_{j=1}^m |f_{ij} - \mu_i| \quad (5)$$

3.2.1. مقادیر شیلی

روش های ذکر شده در بالا راهکار های مفیدی برای شناسایی و بینگی های ممکن است منجر به مدل پیش بینی با مالکرد پهنه شوند. یک رویکرد جدید و جالب، نهانه تباری برای انتخاب و بینگی های تاثیر بالا بر پیش بینی، بلکه برای توضیح اینکه چرا در روش های بدینو ناظر یک رخداد خاص به عنوان ناهنجار شناختی داده، مقادیر شاپلی (Shapely values) هستند [66]. این مقادیر تجربی تخصیصاتی در طبقه بندی بازی های انتلاقی معروف شدند. این روش برایه یکتابع ارزش (value function) تعریف می شود که با π در Δ^S برای یک بازیکن مجموعه N نشایس دارد. مقدار شاپلی π_i نام دهدنگی بهم یک بینگی خاص در پرداخت نهایت است. که بصورت وزار و مجموعه π شده بر تمام کوبک های ممکن حسابه می شود:

$$\phi_i(v) = \sum_{\substack{S \subseteq V \\ i \in S}} \frac{|S|!(n - |S| - 1)!}{(n \setminus |S|)!} (v(S \cup \{i\}) - v(S)) \quad (6)$$

که در آن M مجموعه‌ای تمام بازیکنان را نشان می‌دهد، نتابیرین مقدار شپلی بازی (v, n) برای توزیع سود کل (λ) میان بازیکنان، متناسب با سهم هر یک، استفاده می‌شود [33]. در زمینه‌ی یادگیری ماشین به طور کلی و تشخیص ناهنجاری (AD) به طور خاص، یک بازیکن i - متناسب را کی از ویژگی‌های مجموعه‌ای دارد: است؛ به این ترتیب، n نشان‌هندگی تعداد کل ویژگی‌های روزدی است. به طور معمکوس، مقارن شپلی برای ویژگی $i \in n$ ، میانگین وزن در سهم بهای ن- ویژگی است. بر اساس معادله‌ی (6)، m_i نوان پیش‌بینی را برای مقادیر ویژگی‌های موجود در مجموعه S که S ن- ویژگی است.

برای مجموعه‌ای از ویژگی‌های استفاده شده برای آموزش مدل است — محاسبه کرد، به طوری که این مقادیر بر اساس پیرامونهایی از ویژگی‌های شفافیتی S نیستند، به صورت حاشیه‌ای (marginalized) (marginalized) در نظر گرفته می‌شوند [67].

$$v_x(S) = \int f(x_1, \dots, x_n) dP(x \notin S) - E_X[f(X)] \quad (7)$$

زیر مینهای مدل های یادگیری ماشین، **X**-برداری از مقادیر ویژگی های نمونه ای است که قرار است توضیح داده شود، و n تعداد ویژگی ها را نشان می دهد. مقادیر شپلی (Shapely values) دارای خاصیت تقارن مستند؛ به این معنا که اگر سهم دو ویژگی برابر باشد، مقدار شپلی آن ها نیز برابر خواهد بود، و **y**-برداری که سهمی در پیش بینی ندانند، مقدار شپلی صفر خواهد داشت. این روش همچنین دارای خاصیت بهره وری (efficiency) است، به این معنا که مجموع سهم ویژگی ها برابر با تفاوت بین $b_i - b_j$ باید باشد.

مسئله اصلی در محسنهای مقادیر شپلی برای انتخاب ویزگی‌ها این است که این مقادیر نیازمند یک مجموعه‌داده برجسب‌خورده یا پیش‌بینی برای توضیح هستند. در مورد ما، روش‌های بدون ناطر مورد استفاده قرار گرفته‌اند و هدف اولیه، ارائه توضیحی برای اینکه چرا یک رخداد خاص به عنوان ناهنجار شناسایی شده، می‌باشد. این کاربرد به خوبی با مقادیر شپلی هم خوانی دارد. با این حال، می‌توان اهمیت ویزگی‌ها را بر اساس رخدادهای ناهنجار شناسایی شده و مقادیر شپلی محسنه شده نیز تعیین کرد. این روش‌له می‌تواند به طور قابل توجهی فضای ویزگی‌های مجموعه‌داده را کاهش دهد و در عین حال، پتانسیل فراز، نخ شناسایر، خدادهای ناهنجار، این داشته باشد.

4. مجموعه‌داده

مدفعتی از پیوستن UPC به GuifiSants، انجام فعالیت‌های پژوهشی بود در زمان نگارش این مقاله، حدود ۶۰ گره در شبکه‌ی

چند ده کاربر از این شبکه به عنوان تنها راه دسترسی خود به اینترنت استفاده می‌کنند. در [71] یک صفحه‌ای وب برای پایش زندگی GuifiSants وجود دارد که به صورت ساعتی به روزرسانی می‌شود. تحلیل‌های فنی مربوط به GuifiSants را می‌توان در [72] یافت.

مجموعه داده از نمونه های داده ای که هر ۵ دقیقه از هر گره جمع آوری شده اند، ساخته شده است. این مجموعه داده به صورت عمومی در [19] در دسترس قرار دارد. این کار از طریق یک اتصال دائمی ssh با یک سرور مرکزی پایش به هر گره در شبکه می شن انجام شده است، که از برای اجرای دستورات استاندارد سیستم استفاده شده است. خروجی این دستورات سپس تجزیه می شود تا داده ها استخراج شوند. مزیت این روش آن است که نیازی به نصب نرم افزار اضافی یا اعمال تغییرات در گره ها نیست. این موضوع از آن جهت مهم است که کاربران مالک گره های خود مستثنی. بنابراین، تنها با اجازه کاربران می توان یک کلید عمومی را برای دسترسی ssh به گره ها جهت پایش نصب کرد.

داده‌ها از طریق خواندن متغیرهای هسته‌ی لینوکس که از طریق سیستم فایل /proc در دسترس هستند، به دست آمداند. برای مثال، مسیر /proc/net/dev برای خواندن شمارنده‌های مانند تعداد بایت‌ها و پستهای ارسال شده و دریافت شده از طریق هر اوسط، /proc/stat که اطلاعاتی درباره فعالیت هسته ارائه می‌دهد، /proc/meminfo برای استفاده‌ی حافظه، وغیره. متغیرهای هسته‌ای به دو نوع تقسیم می‌شوند (i) مقادیر مطلق، مانند میکرینگین یا پردازنده در یک دقیقه، و (ii) شمارنده‌هایی که به صورت یکنواخت افزایش می‌باشد، مانند تعداد بسته‌های ارسال شده. ما متغیرهای شمارنده‌محور را با تقسیم اختلاف بین دو نمونه متوالی بر اختلاف زمانی آنها، به نزخ تبدیل کردیم.

برچسب‌های زمانی متناظر بر حسب ثانیه در نظر گرفته شده‌اند. نمونه‌هایی با نرخ منطقی که هنگام راه‌اندازی مجدد یک گروه با زمانی که یک شمارنده به مقدار بیشینه خود می‌رسد و دوباره از استندا شروع می‌شود، رخ می‌دهند، حذف شده‌اند. مجموعه‌داده شامل ویرگی‌های مرتب‌با ترافیک و غیر-ترافیکی است. ویرگی‌های ترافیکی از شمارنده‌های موجود در سیسیور /proc/net/dev در سیستم فایل /proc/ لینوکس استخراج شده‌اند. برای هر گروه، شمارنده‌های مربوط به بایت‌ها و بسته‌های دریافتی و ارسال شده از طریق واسطه‌های WiFi و Ethernet

برای هر گره، مجموع مقادیر شمارندهای برای هر دو نوع واسطه (WiFi و Ethernet)، و همچنین مجموع و تغاضل بایتها و بستههای دریافتی و ارسال شده از طریق تمام واسطهای نیز لحاظ شده‌اند. یادآوری می‌شود که تمام ویزگی‌های شمارندهای طبق توضیح قبلی به نزخ تبدیل شده‌اند. برای مثال، ویزگی‌های sum.xb.rate-24 و eth.txb.rate-24 مجموع بایتها از طریق واسطهای Ethernet و sum.xb.rate-24 به ترتیب به نزخ ارسال بایتها از طریق واسطهای WiFi و Ethernet.

ویزگی های غیرتاریکی شامل تعداد پردازه ها، میانگین بار پردازنه (CPU load)، softirq (softirqs)، context switches (context switches)، وغیره هستند. برای اختصار، تمام ویزگی های جمع آوری شده در اینجا فهرست نشانده اند. فهرست کامل ویزگی ها همراه با توضیح مختصات در ذیل آمده است.

در مجموع، داده‌های جمع‌آوری شده‌اند و شامل ۲۳۸۷ و ۲۳۷۶ گره هستند. برای ارزیابی اثربخشی روش‌های یادگیری مامشن در تشخیص ناهنجاری‌ها، مراحل زیر انجام شده‌اند: در تاریخ ۱۴ آوریل ۲۰۲۱ یکی از دو روزهای مش (گره ۲۴) دچار خرابی شد و جایگزین گردید. بدلیل این خرابی، نمونه‌های مربوط به این گره بین ساعت ۱۰:۵۵ تا ۱۷:۴۰ روز ۱۴ آوریل در دسترس نبودند. برای مجموعه‌ای آزمایشی، نمونه‌های جمع‌آوری شده در بازه‌ی سه روزه‌ی وقوع خرابی (۱۳، ۱۴ و ۱۵ آوریل) استفاده شدند (۶۹۴ نمونه). برای مجموعه‌ای آموزشی، نمونه‌های جمع‌آوری شده در چهار هفتگی منتهی به مجموعه‌ای آزمایشی استفاده شدند (۲۷۳۷ نمونه). شکل ۲ و یزدگی ترا فکی ۲۴ sum.xb.rate-24 را در

آزمایش‌ها و نتایج

در این بخش، جزئیات آزمایش‌های انجام شده با استفاده از روش‌های بدون ناظر تشخیص ناهمجاري (AD) ارائه می‌شود. تمام آزمایش‌ها روی یک سرور IBM Power SC9221 با پردازندهی ۱۶۰ گیگابایت RAM و ۴ کارت گرافیک Nvidia Power9 با فرکانس ۳.۷ گیگاهرتز، ۶۴۴ گیگابایت حافظه RAM و ۳۲ گیگابایت DDR5 NVLink انجام شدند.

¹ <https://www.ibm.com/downloads/cas/KO4BOJ3N>

² <https://www.nvidia.com/en-us/data-center/v100/>

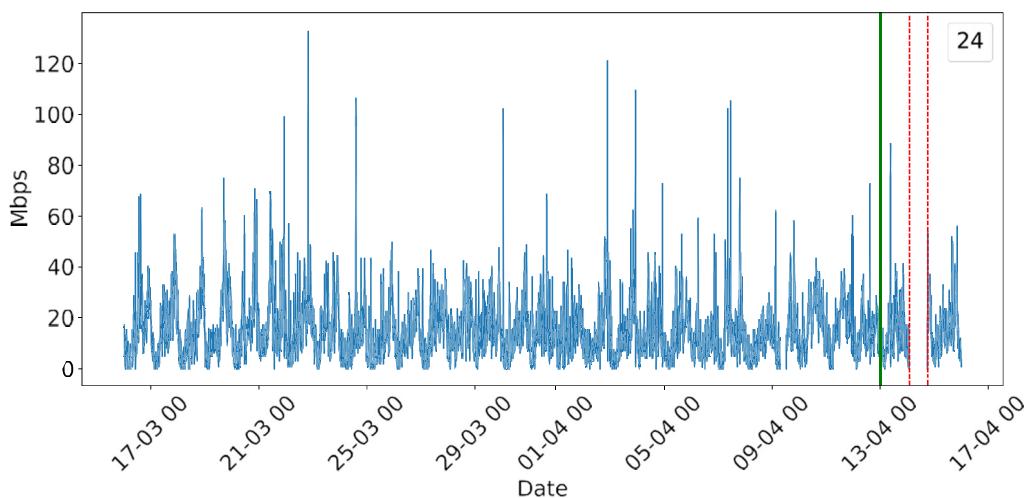


Fig. 2. Plot of the sum.xb.rate-24 traffic feature (sum of received and transmitted traffic over node 24) during the training and testing set (left and right of the solid lined, respectively). Dashed lines show the gateway failure interval. Peaks and valleys show daily activity and inactivity periods. Dates in the x-axis are formatted as day–month hour.

ما از چهار روش یادگیری ماشین معرفی شده در بخش ۳ استفاده کردیم، این روش‌ها به دلیل تفاوت‌های بنیادین در رویکردن به تشخیص ناهنجاری (AD) انتخاب شده‌اند. آزمایش‌ها با استفاده از زبان پایتون و کتابخانه‌های scikit-learn [73]، Isolation Forest برای pyod [74] و PCA و CBLOF [75] اجرا شده‌اند.

آزمایش‌ها از مجموعه‌ای از مراحل شناخته شده پیروی می‌کنند. ابتدا داده‌های خام قالب‌بندی، پاکسازی و نرمال‌سازی (hyper-parameters) می‌شوند سپس چندین روش تشخیص مبتنی بر یادگیری ماشین اجرا می‌شوند تا بهترین پارامترهای تنظیمی شناسایی شوند. پس از آن، روش‌های انتخاب ویژگی برای بهبود نتایج اولیه به کار گرفته می‌شوند. در نهایت مجموعه‌ی دوم آزمایش‌ها با زیرمجموعه‌ی جدیدی از داده‌های اصلی اجرا شده و نتایج نهایی تحلیل می‌شوند. اسکریپت‌های پایتون مورد استفاده برای پیاده‌سازی مجموعه‌داده‌ها در مخزن عمومی زیر در دسترس هستند:

<https://github.com/llorenç/ml-comcom>

مانند تمام وظایف یادگیری ماشین، درک و پاکسازی داده‌ها یکی از زمان‌برترین و حیاتی ترین مراحل است. در آزمایش‌های ما، ویژگی‌های که در بازه‌ی زمانی انتخاب شده دارای واریانس پایین بودند، حذف شدند و ویژگی‌های با واریانس پایین به صورت سراسری و با دقت گرفتن تمام گره‌های شبکه می‌شناختی شده‌اند. داده‌های آموزشی شامل ۷۲۲۷ نمونه هستند که پس از حذف ویژگی‌های کم توجه، هر نمونه دارای ۱۵۸۵ ویژگی است. مجموعه‌ی آزمایش نیز شامل ۶۹۴ نمونه با همان فضای ویژگی‌های مجموعه‌ی آموزشی است.

نرمال‌سازی داده‌ها در صورت اعمال نادرست بر مجموعه‌داده‌های نامتوافق می‌تواند عملکرد روش‌های یادگیری ماشین را بهشت کاهش دهد. لازم می‌شود که اختلافات میان ویژگی‌های مجموعه‌داده به درستی نرمال شوند. مقادیر کم اهمیت و همچنین مقادیر غایل باید در یک بازه‌ی قابل قبول قرار گیرند [75]. ماروش min-max را انتخاب کردیم که داده‌ها را در بازه‌ی [۰, ۱] نرمال‌سازی می‌کند، بر اساس رایطه‌ی زیر:

$$X_n = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (8)$$

مقادیر نرمال شده حاصل که با نماد X_n نمایش داده می‌شوند، این مزیت را دارند که روش میان ویژگی‌ها را حفظ کرده و در نتیجه، سوگیری را عملاً از بین می‌برند. افزون بر این، در برخی روش‌های یادگیری ماشین (مانند یادگیری عمیق و مدل‌های مبتنی بر شبکه‌های عصبی)، نرمال‌سازی صحیح داده‌ها نرخ همگرایی را کاهش می‌دهد.

در مورد PCA، ما درایتیک که اعمال نرمال‌سازی min-max صرفاً بر ویژگی‌های غیرترافیکی مناسب‌تر است. ویژگی‌های ترافیکی با تقسیم هر بردار ویژگی بر میانگین بیشینه‌ی مجموعه ویژگی‌های ترافیکی نرمال‌سازی شده‌اند. از آنجا که نسبت به بازه‌های نرمال شده ویژگی‌ها سیاست حساس است، این روش باعث می‌شود که همیت بیشتری به ویژگی‌های ترافیکی نسبت به ویژگی‌های غیرترافیکی داده شود، در حالی که اهمیت نسیی گرهاتی با مقادیر ترافیکی بالاتر نیز حفظ می‌شود.

بیشتر کتابخانه‌های مربوط به روش‌های بدون ناظر برای تشخیص ناهنجاری و نقاط پرت، نیاز دارند که یک عامل آلدگی (contamination factor) مورد انتظار برای آموزش مشخص شود. از آنجا که رخدادهای ناهنجار به ندرت اتفاق می‌افتد و ما می‌خواهیم از مشتّه‌های کاذب جلوگیری کنیم، تا حد امکان، مقادیر آلدگی (contamination) را روی مقدار $\alpha=0.005$ تنظیم کردیم.

Table 1

| ML method | Parameters | Value |
|------------------|-----------------|---------------|
| PCA | PC number | 45 |
| Isolation Forest | n_estimators | 20 |
| | max_samples | 0.7 |
| | max_features | 1.0 |
| CBLOF | n_clusters | 8 |
| | alpha | 0.9 |
| | beta | 5 |
| VAE | encoder_neurons | [128, 64, 32] |
| | decoder_neurons | [32, 64, 128] |
| | epochs | 30 |
| | dropout_rate | 0.2 |
| | activation | ReLU |

آنسته‌ی تشخیص ناهنجاری‌ها بر اساس صدک $1-\alpha$ از مجموعه‌ی آموزشی تعیین می‌شود. برای مجموعه‌ی آموزشی ما با ۷۲۲۷ نمونه، این عامل آلدگی منجر به $37=7237 \times 0.01$ ناهنجاری می‌شود. توجه داشته باشید که در مجموعه‌ی آزمایش شامل ۶۹۴ نمونه، تحت شرایط عادی انتظار می‌رود که حدود $4=694 \times 0.01$ ناهنجاری وجود داشته باشد. با این حال، بدليل خرابی شبکه که در بازه‌ی آزمایش رخ دارد، انتظار داریم روش‌های مختلف یادگیری ماشین تعداد بیشتری ناهنجاری را شناسایی کنند.

برای هر یک از الگوریتم‌ها، لازم بود که پارامترهای تنظیمی (hyper-parameters) به صورت دستی تنظیم شوند تا رخدادهای ناهنجار در بازه‌ی زمانی مشخص شده که می‌دانیم ناهنجاری در رخ دارد. گروه‌بندی شوند. جدول ۱ پارامترهای تنظیمی مورد استفاده برای هر روش تشخیص ناهنجاری را شناس می‌دهد. این مقدار:

بهینه‌سازی شده‌اند و یک فضای تنظیم دستی برای پارامترهای تنظیمی پارامترها با استفاده از روش جستجوی تصادفی فضای جستجوی پارامترها (parameter search space) :

در مورد PCA، تنها پارامتر قابل تنظیم، تعداد مؤلفه‌های اصلی (PC) است. برای تعیین تعداد مؤلفه‌ها، از روش رایج انتخاب تعداد ابعاد استفاده کردیم، که ۹۵٪ از واریانس یافته‌مانده را حفظ می‌کند.

در مورد CBLOF، از مقادیر پیش‌فرض برای تمام پارامترها استفاده شده است، چرا که این مقادیر بهترین نتایج را ارائه داده‌اند.

پارامترهای VAE شامل نرخ dropout نیز می‌شوند که به تعمیم پذیری مدل کمک کرده و از پیش‌پردازش (overfitting) جلوگیری می‌کند. ساختار پخش‌های encoder و decoder در VAE در نیز به صورت متقاضان طراحی شده‌اند.

یکی از ملاحظات مهم این است که اندازه دسته (batch size) را ایجاد با ۳۲ تنظیم کردیم، هرچند ساخت‌افزاری که آزمایش‌ها روی آن اجرا شده توانایی پیاده‌سازی دسته‌های بسیار بزرگ‌تری را دارد، اما برای هر استایی با ساخت‌افزارهای محدود تر مانند برد Nvidia Jetson Nano3 Nano3، از مقدار کوچک‌تری استفاده کردیم، رویکرد مشابهی نیز در تعیین تعداد دوره‌های آموزش (training epochs) (تجاذب شده است).

ما آگاه هستیم که اندازه دسته و تعداد دوره‌های آموزش هر دو از پارامترهای تنظیمی مهم هستند، اما هدف نهایی ما این است که بینیم:

Table 2
Results of ML method based experiments.

| ML method | Num. of features | Training [s] | Inference [s] | Testing anomalies |
|------------------|--------------------|--------------|---------------|-------------------|
| PCA | (all) 1585 | 1.25 | 0.14 | 151/122 |
| | (only traffic) 880 | 0.88 | 0.11 | 13/11 |
| Isolation Forest | (all) 1585 | 2.33 | 1.04 | 74/69 |
| | (only traffic) 880 | 0.97 | 0.37 | 10/4 |
| CART OF | (all) 1585 | 18.28 | 2.71 | 125/115 |
| | (only traffic) 880 | 3.42 | 0.09 | 3/2 |
| VAE | (all) 1585 | 58.61 | 1.09 | 134/122 |
| | (only traffic) 880 | 39.36 | 0.49 | 23/12 |

نحوه عملکرد روش‌های پادگیری ماشین‌ذکر شده در سترایبووهایی از نوع Edge/Fog مورد بررسی قرار گرفته است. باید توجه داشت که بهدلیل نبود مجموعه داده برچسب خورده، استفاده از تکنیک‌های معمول بهینه‌سازی پارامترهای تنظیمی عملاً غیرممکن است. در عوض، تمرکز ما بر یافتن پارامترهایی است که منجر به مدلی با پایداری و تکراری‌بیشتر بالا شوند. در این مطالعه، این موضوع با بررسی مدل‌هایی سنجیده شده که به طور پیوسته ناهنجاری‌ها را در بازه‌ی آزمایشی شناسایی می‌کنند.

شایان ذکر است که پارامترهای تنظیمی الگوریتم‌ها به صورت تصادفی یا مستقل انتخاب نشده‌اند، چرا که در سیاری موارد با یکدیگر مرتبط هستند. اگرچه در آزمایش‌های ما از تکنیک‌های بهینه‌سازی بدون راهنمایی (unguided optimization) استفاده شده، فضای پارامترهای تنظیمی برای هر الگوریتم پس از بررسی‌های قابل توجه تعییف شده است.

برای مثال، در موردنامه Isolation Forest، تعداد کم تخمین‌گرها (estimators) همراه با حداکثر تعداد ویزگی‌ها و نمونه‌ها می‌تواند منجر به پیش‌پرازش مدل شود. در آزمایش‌های ما، تعداد تخمین‌گرها در بازه‌ی [0.1, 100]، اندازه‌ی نمونه در بازه‌ی [0.03, 1] و تعداد ویزگی‌ها در بازه‌ی [0.2, 10.0] تعییف شده‌اند.

بهطور مشابه، در مودل VAE، تعداد دوره‌های آموزش (epochs) در بازه‌ی [0.5, 100] و نرخ dropout در بازه‌ی [0.01, 0.8] تنظیم شده‌اند. سه نوع تابع فعال‌سازی مورد آزمایش قرار گرفته‌اند: 'elu'، 'relu' و 'parametric_relu'. ساختار encoder بهصورت متقاضن طراحی شده‌اند و معمولاً الگوی نزولی و صعودی را دنبال می‌کنند. در آزمایش‌های ما، تعداد اولیه‌ی نورون‌ها در encoder 32، در بازه‌ی [512, 12] تعریف شده است.

می توان گفت که تنظیم Isolation Forest دشوارترین بخش بوده است. همان طور که در بخش ۳،۲ توضیح داده شده، Isolation Forest شامل مراحل متعددی است که به طور قابل توجهی تحت تأثیر تصادفی بودن قرار دارند. این ویژگی در بسیاری موارد مفید است، اما می تواند منجر به نتایج ناسازگار شود. اگر از بذر تصادفی (random seed) استفاده نشود، هر بار آموزش مدل ممکن است نتایج متفاوتی تولید کند. پس از صدها اجرای آزمایشی، تضمین گرفتیم از تعداد نسبتاً کمی تخمین گر (20×20 عدد)، حداقل تعداد ویژگی ها برای آموزش هر تخمین گر، اندازه هی نمونه^۷، استفاده کنیم تا از بیش برآش خله گر، شود.

نتایج تمام آزمایش‌ها در جدول ۲ ارائه شده‌اند. برای هر الگوریتم، زمان آموزش و استنتاج (inference)، تعداد ناهنجاری‌های شناسایی شده در مجموعه آزمایشی، و تعداد نمونه‌هایی که در بازه‌ی خرابی دروازه قرار دارند (۱۲۲ نمونه در این بازه جمع اوری شده‌اند) گزارش شده‌اند. آن جا که خرابی دروازه بهوضوح یک وضعیت ناهنجار است، تعداد نمونه‌های شناسایی شده به عنوان ناهنجار در این بازه می‌تواند به عنوان معامله‌کرد الگ. سه تا از دو نظر گفته شود.

جدول ۲ برای هر الگوریتم، تعداد ناهنجاری‌های شناسایی شده با استفاده از تمام و بیزگی‌ها و فقط و بیزگی‌های ترافیکی را نشان می‌دهد. با مقایسه این دو حالت، مشاهده می‌شود که استفاده از تمام و بیزگی‌ها عملکرد الگوریتم‌ها را به طور قابل توجهی افزایش می‌دهد. برای مثال، در مورد VAE با استفاده از تمام و بیزگی‌ها، ۱۳۴ ناهنجاری شناسایی شده‌اند که تمام ۱۲۲ نمونه‌ی مرتبوط به بازه‌ی خرابی دروازه را شامل می‌شوند. در حالی که با استفاده از و بیزگی‌های ترافیکی تنها، فقط ۲۳ ناهنجاری شناسایی شده‌اند که تنها ۱۲ مورد از آن‌ها در بازه‌ی خرابی قرار دارند.

از نظر زمان اجراء، بهوضوح مشخص است که استنتاج مدل زمان کمتری نسبت به آموزش نیاز دارد. در آزمایش‌های ما، زمان استنتاج فقط روی مجموعه‌ی آموزشی اندازه‌گیری شده است، چرا که این مجموعه به مراتب بزرگ‌تر از مجموعه‌ی آزمایشی است.

گام بعدی در آزمایش‌ها، بررسی عملکرد روش‌های یادگیری ماشین با تغییر اندازه‌ی مجموعه داده بود. برای این منظور، ابتدا تعداد نمونه‌های مورد استفاده در مجموعه‌ی آموزشی را تغییر دادیم. نتایج در شکل ۳

نمونه‌هایی از تعداد روزهایی که در محور افقی (abscissa) نشان داده شده‌اند، جمع‌آوری شده‌اند. نمونه‌های آموزشی از روز با لافاصله قبیل از مجموعه‌ی آزمایشی گرفته شده‌اند و تا تمام روزهای چهار هفته‌ی قبیل ادامه دارند. شکل ۳ عملکرد بسیار مقنواتی را میان روش‌های مختلف یادگیری ماشین نشان می‌دهد. در حالی که VAE در صورت استفاده از نمونه‌های تعداد کمی روز، تعداد زیادی ناهنجاری (و در CBLOF، PCA و Isolation Forest) نتیجه مثبت‌های کاذب (تولید می‌کنند. انتها تعداد کمی ناهنجاری شناسایی می‌کند و در نتیجه تعداد زیادی منفی کاذب دارد.

از سوی دیگر، زمانی که از نمونه‌های بیش از ۱۳ روز استفاده می‌شود، تعداد ناهنجاری‌های شناسایی شده توسط VAE تقریباً ثابت باقی می‌ماند و تمام نمونه‌های مربوط به بازی خارجی دروازه را بهدرستی به عنوان ناهنجار شناسایی می‌کند. تعداد ناهنجاری‌های شناسایی شده توسط سایر روش‌ها حتی پس از استفاده از داده‌های بیش از ۲۰ روز نوسان دارد. بنابراین، می‌توان نتیجه گرفت که در آزمیش‌های ما، VAE قادر است با تعداد نمونه‌های کمتر، ناهنجاری‌ها را بهطور قابل اعتماد شناسایی کند.

در مرحله بعد، روش‌های یادگیری ماشین را با تغییر تعداد و پیزگی‌ها بررسی کردند، و پیزگی‌ها از یک تا تمام مجموعه، بر اساس میزان اهمیت مرتبت شده و تعداد نهنجاری‌ها محاسبه شد. برای تعیین اهمیت و پیزگی‌ها، از نمودار مشارکت آماری Q در PCA (بخش ۳،۱) و روش‌های انتخاب و پیزگی شرچ داده شده در بخش ۳،۵ استفاده شده است.

شکل ۴ تعداد ناهنجاری‌های شناسایی شده در مجموعه‌ی آزمایشی و تعداد آن‌ها در بازه‌ی خارجی دروازه را با توجه به تعداد ویژگی‌های استفاده شده برای آموزش نشان می‌دهد. ناهنجاری‌های محاسبه شده با روش‌های یادگیری ماشین در هر ردیف، بر اساس نوع روش انتخاب ویژگی که در بالای هر سوتون آمده، تقسیم شده‌اند. تعداد ویژگی‌ها بر اساس مقدار مطلق نزولی حاصل از هر روش انتخاب ویژگی مرتب شده‌اند.

این شکل نشان می دهد که روش های یادگیری ماشین بررسی شده، بسته به تعداد ویژگی های استفاده شده، رفتار بسیار متفاوتی دارند. Isolation Forest حساس ترین روش است، حتی با تعداد زیادی ویژگی، افزودن تنها یک ویژگی می تواند تعداد نقاط شناسایی شده به عنوان ناهنجار را به طور قابل توجهی تغییر دهد. VAE پایدارترین عملکرد را دارد. در واقع، با استفاده از PCA، MAD و SHAP به عنوان در مقابل، VAE روش انتخاب ویژگی، تعداد ناهنجاری های شناسایی شده توسط VAE تقریباً ثابت باقی می ماند، زمانی که تعداد ویژگی ها بیش از حدود یک چهارم کل مجموعه باشد.

در مورد روش‌های انتخاب ویژگی، شکل ۴ نشان می‌دهد که روش kurtosis ضعیف‌ترین عملکرد را دارد. برای سایر روش‌ها، شکل ۴ نشان می‌دهد که بندهای واضحی وجود دارند و بسته به الگوریتم یادگیری ماشین، یک روش انتخاب ویژگی ممکن است نتایج بهتری ارائه دهد.

همان روند که پیش‌تر توضیح داده شد، پارامتر آلوگو نظیمنشده در مرحله‌ای آموزش منجر به شناسایی ۳۷ ناهنجاری از میان ۲۲۳۷ نمونه شد. همچنین باید اشاره کرد که بازیگر زمانی انتخاب شده به گونه‌ای بوده که فرض می‌شود هیچ رخداد ناهنجاری در آن رخ نداده است. با این حال، به جز PCA، سایر روش‌های یادگیری ماشین عمدتاً ناهنجاری‌های مشابهی را شناسایی کرده‌اند. این موضوع به‌وضوح در شکل ۵ (a). قابل مشاهده است که ناهنجاری‌های همپوشان شناسایی شده توسط چهار روش یادگیری ماشین در مجموعه‌ای آموزشی را نشان می‌دهد. بیشترین تفاوت میان PCA و سایر روش‌ها مشاهده می‌شود که احتمالاً به دلیل نرمال‌سازی متفاوت اعمال شده در PCA است.

با این حال، اگر مجموعه‌ای آزمایشی را در نظر گیریم، تفاق بالایی میان تمام روش‌های یادگیری ماشین

و وجود دارد، همان طور که در شکل ۵ (b) نشان داده شده است. ابتدا توجه داشته باشید که تعداد ناهنجاری‌ها بسیار بیشتر از ۴ موردی است که انتظار می‌رفت. این موضوع بدليل بازه‌ی خوبی دروازه است که بیشتر ناهنجاری‌ها در آن یافت می‌شوند، همان‌طور که در شکل ۵ (c) نشان داده شده است. برای مثال، شکل ۵ (c) نشان می‌دهد که PCA و VAE تمام ۱۲۲ نقطه‌ی مربوط به بازه‌ی خوبی دروازه را به عنوان ناهنجار شناسایی کرده‌اند. با این حال، PCA در مجموع ۱۵۱ نقطه‌ی ناهنجار در مجموعه‌ی آزمایشی شناسایی کرده، در حالی که VAE تنها ۱۳۴ مورد را شناسایی کرده است. احتمالاً تعداد بیشتر نقاط شناسایی شده توسط PCA ناشی از پیشرازش مدل است.

برای درک بهتر روش‌های یادگیری ماشین مقایسه شده، شکل ۶ یک نگاشت دو بعدی PCA از مجموعه‌ی آموزشی را نشان می‌دهد (Mölfetta et al., 2018). این نگاشت برای Isolation Forest (Isolation Forest) و PC1 و PC2 برای الگوریتم‌های CRLOE و VAE تهیه شده است.

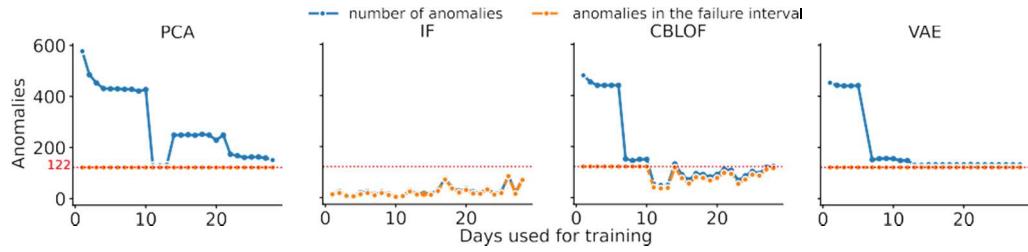


Fig. 3. Number of anomalies found in the testing set varying the number of samples used for training (samples gathered during the previous days). The figure also shows the number of anomalies obtained within the gateway failure interval (dashed line), and the number of points in this interval (122).

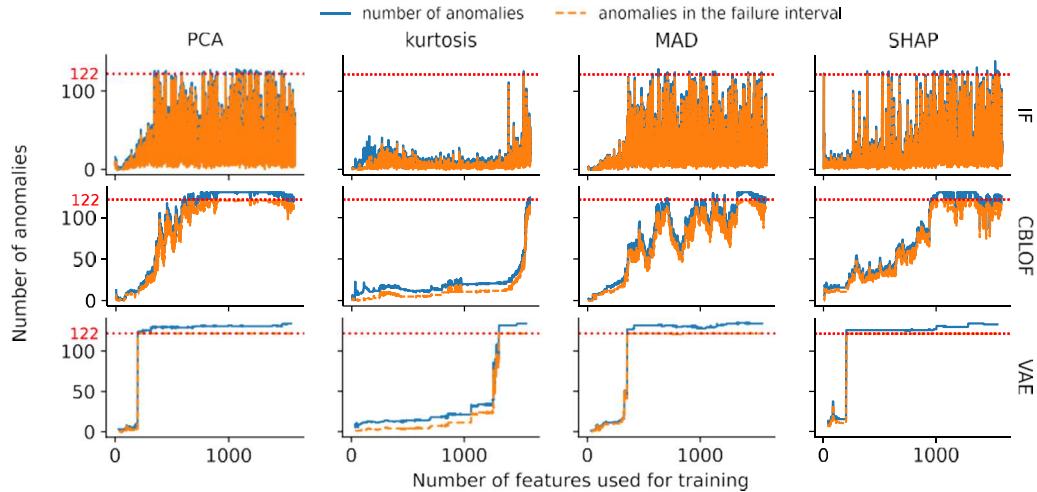


Fig. 4. Number of anomalies found in the testing set, as in Fig. 3, but varying the number of features used for training. The features are selected with different methods (shown at the top of each column).

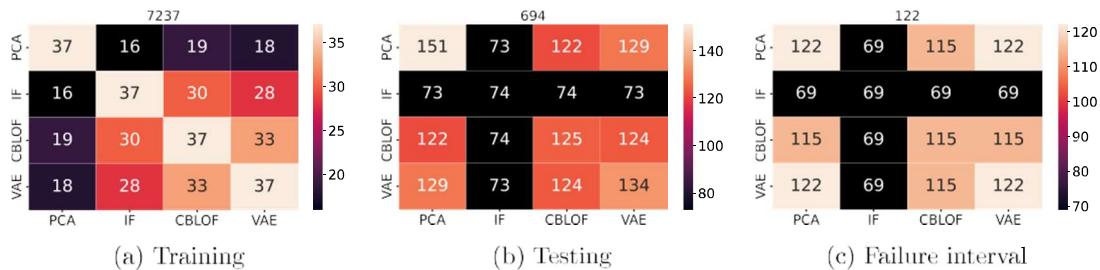


Fig. 5. Detected overlapping anomalies. Each row/column represents an AD method. Each cell of the heatmap represents the number of overlapping anomalies detected by that pair of methods. At the top of each figure there is the total number of points of the set.

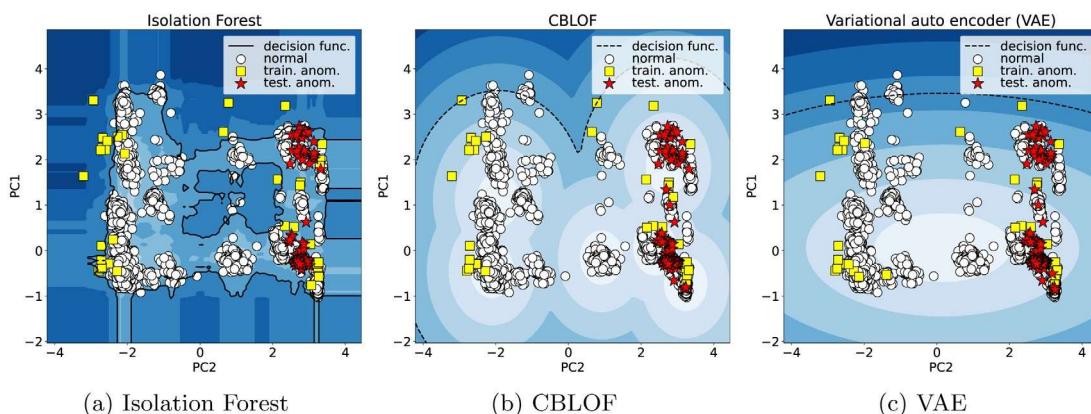


Fig. 6. Decision boundaries of the ML methods re-projected using PCA with 2 components. The projected points are those in the training set (circles), anomalies due to the contamination factor in the training set (squares), and anomalies in the test set (stars).

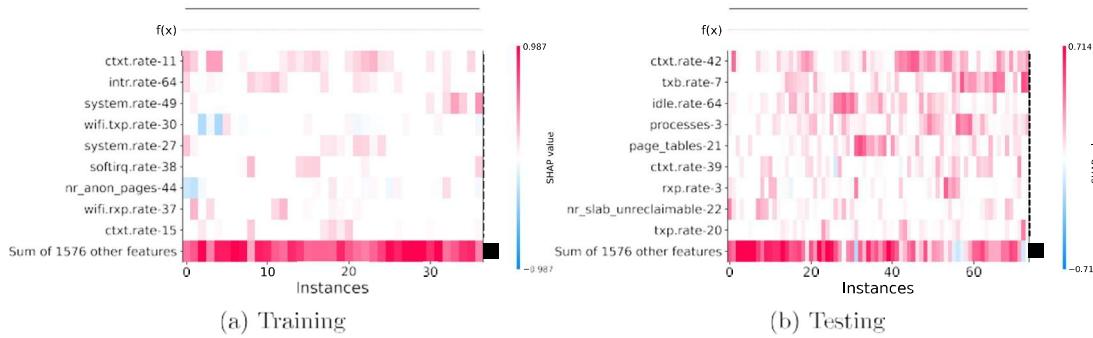


Fig. 7. SHAP heatmap plots for the training and testing anomalies obtained with Isolation Forest. The y-axis shows the model inputs sorted in descending order from top to bottom, for each anomalous event.

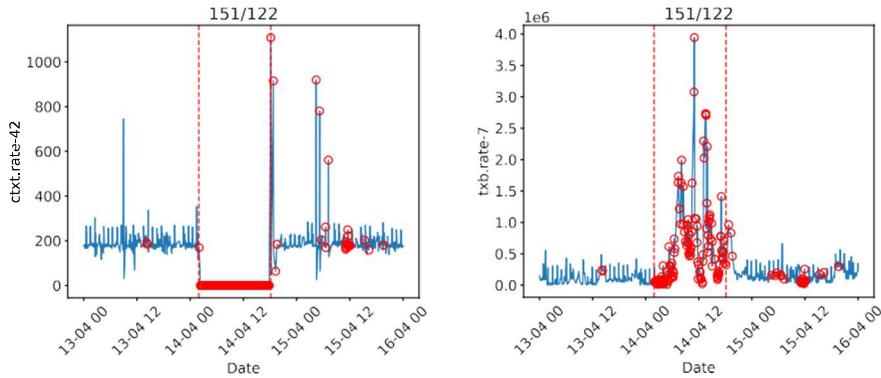


Fig. 8. Features contributing most to SHAP score during the testing set. Vertical lines correspond to the failure interval. Marked samples correspond to anomalies detected by PCA.

نقطه داری مختصات یکسان هستند، زیرا از مقیاس بندی یکسانی برای این روش‌ها استفاده شده است.

ناهنجاری شناسایی شده در مجموعه‌ی آموزشی علامت‌گذاری شده‌اند و ناهنجاری‌های شناسایی شده در مجموعه‌ی آزمایشی نیز نگاشت شده‌اند. علاوه بر این، روش‌ها را روی نگاشت دو بعدی مجموعه‌ی آموزشی اجرا کرده و مرز تضمیم‌گیری حاصل را ترسیم کرده‌اند. توجه داشته باشید که ناهنجاری‌هایی که با استفاده از مجموعه‌ی آموزشی دو بعدی شناسایی می‌شوند (نقاط خارج از مرز تضمیم‌گیری)، با ناهنجاری‌هایی که با استفاده از مجموعه‌ی آموزشی «تصمیم‌گیری» هر روش یادگیری ماشین در مورد اینکه چه چیزی می‌توان به راحتی تفاوت یابی نحوه‌ی «تصمیم‌گیری» را ترسیم کرد. مرز تضمیم‌گیری محاسبه شده برای یک رخداد ناهنجار است و چه چیزی نیست را مشاهده کرد. مرز تضمیم‌گیری می‌تواند مفاهیم پایه‌ای مشابه با Isolation Forest مدل‌های درخت تضمیم‌گیری نظرتال شده بهویزه (Random Forest) (با شده، می‌توان با اطمینان گفت که برخی ویژگی‌های خاص این مدل‌ها در Isolation Forest نیز دیده می‌شوند. شکل ۶ به‌وضوح نشان می‌دهد که بهویزه بازش مدل می‌تواند در مورد Isolation Forest یک مشکل باشد، که منجر به عملکرد ضعیف در داده‌های خارج از نمونه می‌شود.

برای تفسیر ناهنجاری‌ها، شکل ۷ یک نقشه‌ی حرارتی SHAP از ناهنجاری‌های به‌دست آمده از

مجموعه‌های آموزشی و آزمایشی را نشان می‌دهد، در زیرشکل‌های (a) و (b) بهتر تبیّن. در محور افقی (abscissa) رخدادهای ناهنجار نمایش داده شده‌اند، در حالی که محور عمودی (ordinate) (روهی‌های متآسفانه، در مورد روش‌های انتخاب ویژگی، اینپلور می‌گردد) را دارد، می‌توان با اطمینان گفت خوشبینی سلسه‌های روش‌های انتخاب و شباخت در توضیحات، روی یک مقیاس رنگی نمایش داده شده‌اند. در بالای هر زیرشکل، خروجی تابع $f(x)$ با مقادیر پیش‌بینی شده نمایش داده شده که همواره برای ۱ است، زیرا تنها نمونه‌های ناهنجار ترسیم شده‌اند.

در شکل ۷ مشاهده می‌شود که شدت رنگ ناهنجاری‌های به‌دست آمده از مجموعه‌ی آموزشی بسیار کم‌رنگ‌تر و پراکنده‌تر است، در حالی که در مجموعه‌ی آزمایشی رنگ‌ها شدیدتر و پرتکرارتر هستند. این موضوع به‌وضوح نشان می‌دهد که گروهی از ویژگی‌ها به‌طور قابل توجهی تحت تأثیر خرابی دروازه در مجموعه‌ی آزمایشی قرار گرفته‌اند و بنابراین، برای بیشتر ناهنجاری‌های شناسایی شده در این مجموعه، مقدار شپلی بالایی دریافت کرده‌اند.

همچنین جالب است که در شکل ۷ هیچ یک از ویژگی‌هایی که بیشترین سهم را در ناهنجاری‌های شناسایی شده در مجموعه‌ی آموزشی دارند

مقدار آلوگی تنظیم شده، با ویژگی‌هایی که بیشترین سهم را در مجموعه‌ی آزمایشی دارند (ناشی از خرابی دروازه)، مطابقت ندارند. این موضع همان‌طور که انتظار می‌رفت نشان می‌دهد که ناهنجاری‌های شناسایی شده در مجموعه ماهیت متفاوتی دارند.

شکل ۸ یک سری زمانی از دو ویژگی را نشان می‌دهد که بیشترین سهم را در تشخیص ناهنجاری‌ها در مجموعه‌ی آزمایشی دارند مطابق با شکل ۷. (b). این دو ویژگی عبارت‌اند از نرخ تعویض زمینه‌ی پردازنده (CPU context switches) (ctxt.rate-42) و نرخ ارسال بایت‌ها در گره ۷ (txb.rate-7). (a). این دو ویژگی عاری از نرخ تعویض زمینه‌ی پردازنده (CPU context switches) (ctxt.rate-42) و نرخ ارسال بایت‌ها در گره ۴۲ (txb.rate-42)، اما در زمان خرابی دروازه مقدار آن صفر است. دليل این موضوع آن است که در زمان خرابی، گره ۴۲ از شکله جدید و هیچ نمونه‌ای از آن جمع‌آوری نشده است. این نمونه‌های مفقود به مقدار صفر تقطیم شده‌اند.

از سوی دیگر، شکل ۸ نشان می‌دهد که txb.rate-7 در زمان خرابی دروازه مقدار غیرعادی بالاتری دارد. دليل این آن است که گره ۷ در نزدیکی دروازه خراب شده قرار دارد و در زمان خرابی، بیشتر ترافیکی که در دروازه دیگر شکه مش هدایت شده بود را جذب کرده است.

5.1. بحث

نتایج آزمایش ما جالب بوده است، ما دریافتیم که هر ۴ روش تشخیص ML انتخاب شده بر روی مجموعه‌داده ارائه شده به خوبی عمل می‌کنند.³⁵² متأسفانه، در مورد روش‌های انتخاب ویژگی، اینپلور نیست.³⁵³ روشنی که در بیشتر موارد بهترین عملکرد را دارد، می‌تواند بر محاسبه مقدار شپلی است که از نظر محاسباتی گران است.³⁵⁴ VAE با فضای ویژگی کامل بهترین عملکرد را داشت در حالی که جنگل ایزووله‌سازی پس از انتخاب ویژگی می‌تواند بر مقدار شپلی، بیشترین بهبود را داشت.³⁵⁵ به طور کلی، عملکرد CBLOF با زمان‌های آموزش و استنتاج نسبتاً سریع، سازگارترین بود.³⁵⁶ روش انتخاب MAD نیز کاهش قابل توجهی در فضای ویژگی، بهویزه برای روش‌های جنگل ایزووله‌سازی و VAE فراهم کرد.

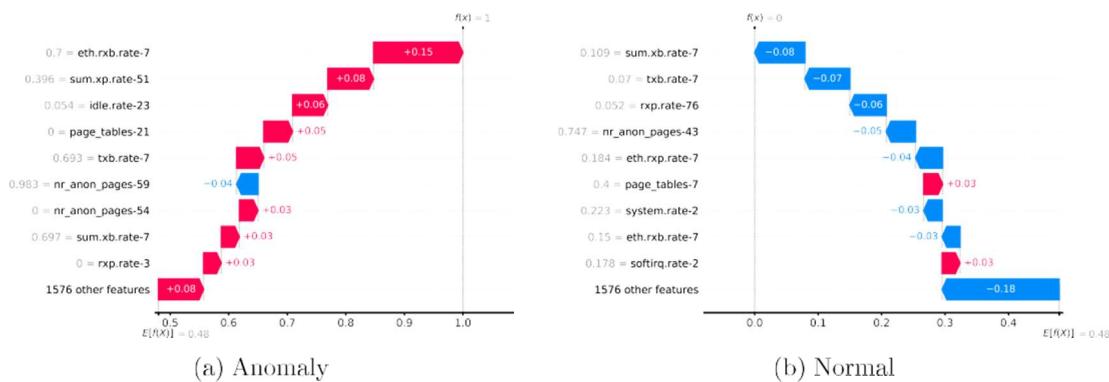


Fig. 9. SHAP representation of an anomalous and normal samples randomly taken from the testing set. At the bottom is the expected value of the model. Each line shows the positive (red) or negative (blue) contribution of each feature to the prediction. The features are sorted in descending order of contribution.

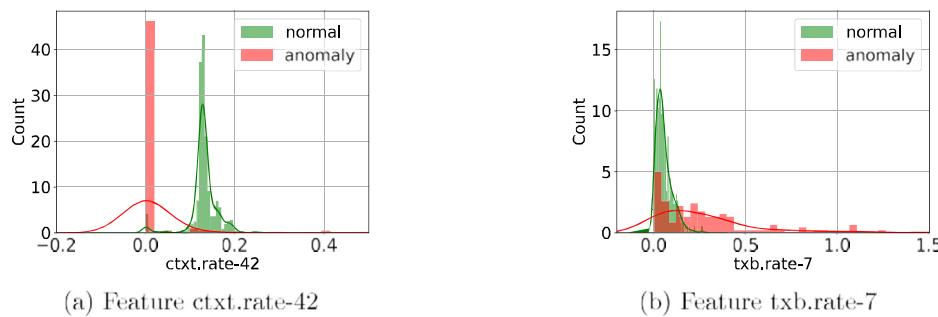


Fig. 10. Feature separability for most impactful features. The figure shows the histograms of the scaled most impactful features for the normal and anomalous events of the testing set.

افزودن ویژگی‌ها بر اساس امتیاز MAD می‌تواند باعث افت قابل توجهی در عملکرد پیش‌بینی شود. یکی از مسائل مطرح شده در آزمایش‌های ما این است که نمی‌دانیم چند نوع رخداد ناهنجار در مجموعه داده وجود دارد. هر چهار روش نمونه‌ها را به صورت ناهنجار یا عادی برجسته‌گذاری می‌کنند، اما هیچ کدام تمايزی میان انواع ناهنجاری‌ها قابل نمی‌شوند. شکل ۹ نمودارهای آبشاری (waterfall plots) حاصل از SHAP را نشان می‌دهد که یک رخداد ناهنجار و یک رخداد عادی را به صورت تصادفی از مجموعه‌ی آبشاری نمایش می‌دهد؛ ویژگی‌ها به ترتیب نزولی مرتب شده‌اند.

در این نمودارها، پیش‌بینی‌ها به ترتیب $f(x)=1$ برای نمونه‌ی ناهنجار و $f(x)=0$ برای نمونه‌ی عادی هستند، با مقدار پایه‌ی $E[f(x)] = 0.48$. این مقدار پایه‌ی میانگین متغیر هدف برای تمام رخدادهای موجود در مجموعه داده را نشان می‌دهد. ویژگی‌هایی که با رنگ قرمز نمایش داده شده‌اند، پیش‌بینی را به سمت ۱ (رخداد ناهنجار) سوق می‌دهند، در حالی که ویژگی‌های آبی آن را به سمت ۰ (رخداد عادی) هدایت می‌کنند. جداولی رخدادهای پیش‌بینی شده به راحتی قابل مشاهده است. این موضوع زمانی که هیستوگرام‌هایی برای تأثیرگذارترین ویژگی‌های مجموعه‌ی آزمایشی ترسیم می‌شود (شکل ۱۰)، نیز صادق است.

اگرچه این اطلاعات مفید هستند، اما همچنان به این پرسشن پاسخ نمی‌دهند: چند نوع ناهنجاری وجود دارد و کاهش فضای ویژگی‌ها چه تأثیری بر پیش‌بینی دارد؟ به احتمال زیاد، با کاهش فضای ویژگی‌ها، توانایی روش‌های تشخیص ما برای شناسایی انواع دیگر ناهنجاری‌ها نیز کاهش می‌یابد. برای مثال، اگر تنها معیارهای CPU در مجموعه داده موجود باشند، شناسایی ناهنجاری‌های مرتبط با حافظه تقرباً غیرممکن خواهد بود.

برای پاسخ به این پرسشن، تصمیم گرفته شده را با استفاده از روش خوشبندی HDBSCAN برای این منظور، الگوریتم (HDBSCAN) (خوشبندی سلسله‌مراتبی مبتنی بر چگالی) با نظری گیرد. برای این انتخاب شد که خود نیز یکی از روش‌های مورد استفاده در تشخیص ناهنجاری‌هاست. این نویز [77] انتخاب شد که حد نیز کمتر از ۰.۳۰ است. برای حفظ سازگاری، از ناهنجاری‌های HDBSCAN شناسایی شده توسط Isolation Forest استفاده کردیم. شکل ۱۱ نشان می‌دهد که این روش شامل ۹۷ رخداد ناهنجار و ۲۰ رخداد ناهنجار به عنوان نویز شناسایی کرده است. از میان این ناهنجاری‌ها، ۱۰۷ مورد مربوط به بازی خارجی دروازه هستند که ۱۴ مورد از آن‌ها به عنوان نویز و ۹۳ مورد در خوش فرار گرفته‌اند.

تفسیر ما از این نتایج آن است که بیشتر رخدادهای ناهنجاری شناسایی شده از یک نوع هستند که با خرابی دروازه مطابقت دارند.

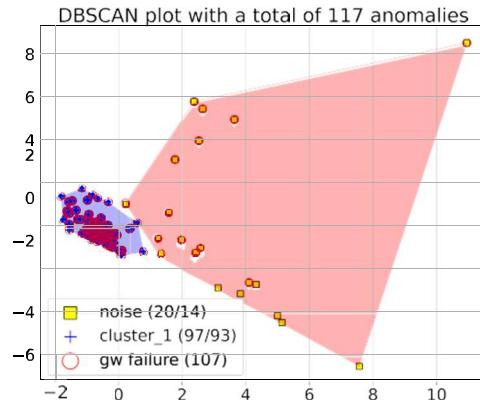


Fig. 11. Anomalous event clustering using HDBSCAN. On the left is the anomalous event cluster (97 points), and on the right is the noise (20 points). 107 points correspond to gateway failure (circles), of which 93 are in the anomalous cluster, and 14 in the noise.

DBSCAN یک چالش مهم است؛ اگر مقدار آن بیش از حد کوچک باشد، بعضی قابل توجهی از داده‌ها به هیچ خوشبندی تخصیص نمی‌یابند و به عنوان نقاط پرت علامت گذاری می‌شوند. اگر مقدار آن بیش از حد بزرگ باشد، تمام خوشبندی در یک خوشبندی بزرگ ادغام می‌شوند. HDBSCAN این مشکل را با ارائه خوشبندی‌های معنادار و نیاز بسیار کم به تنظیم پارامترها برطرف می‌کند. در آزمایش ما، اندازه‌ی حداقل خوشبندی برابر با 30° تنظیم شده است. برای حفظ سازگاری، از ناهنجاری‌های HDBSCAN شناسایی شده توسط Isolation Forest استفاده کردیم. شکل ۱۱ نشان می‌دهد که این روش شامل ۹۷ رخداد ناهنجار و ۲۰ رخداد ناهنجار به عنوان نویز شناسایی کرده است. از میان این ناهنجاری‌ها، ۱۰۷ مورد مربوط به بازی خارجی دروازه هستند که ۱۴ مورد از آن‌ها به عنوان نویز و ۹۳ مورد در خوش فرار گرفته‌اند.

تفسیر ما از این نتایج آن است که بیشتر رخدادهای ناهنجاری شناسایی شده از یک نوع هستند که با خرابی دروازه مطابقت دارند.

6. از نظر پیچیدگی روش‌های یادگیری ماشین انتخاب شده، ابتدا باید اشاره کرد که Isolation Forest (IF) مناسب است و دارای پیچیدگی زمانی خطی با ضریب پایین و نیاز حافظه‌ای کم (بسته به پارامترهای تنظیمی) می‌باشد [1]. به طور مشابه، CBLOF نیز برای داده‌های حجمی مناسب است و در بهترین حالت دارای پیچیدگی زمانی $O(N \log N)$ است [55]. در مقابل، VAE به خاطر پیچیدگی محاسباتی بالا شناخته می‌شود که عمدتاً به ساختار شبکه در مرحله‌ی آموزش بستگی دارد. با این حال، در آزمایش‌های ما این پیچیدگی منجر به نتایج جالبی شد؛ VAE تواست با ساختاری ساده که مستقیماً از ساختار مجموعه‌داده ناشی می‌شود، عملکرد بهتری نسبت به سایر روش‌ها داشته باشد. همچنین، VAE در بهینه‌سازی پارامترهای تنظیمی پایدارترین بودند و در تمام موارد مدل‌های VAE به جز مقادیر افراطی، مدل‌های قابل استفاده تولید کردند.

7. همچنین باید اشاره کرد که آزمایش‌های ما شامل چندین روش یادگیری ماشین دیگر نیز بوده‌اند. نتایجی که در این مقاله ارائه شده‌اند، بر اساس عملکرد هر مدل انتخاب شده‌اند. برای مثال، آزمایش‌هایی با روش‌های مبتنی بر GAN مانند [79] ALAD و AnoGAN [80] انجام دادیم، تفاوت اصلی این دو در آن است که ALAD بر پایه یک GAN دوطرفه ساخته شده که از محاسبات سنگین مرحله‌ی استنتاج در AnoGAN جلوگیری می‌کند. متأسفانه، نتایج تجربی در هر دو مورد ضعیف بودند.

8. همچنان که در ALAD احتیتی با بذر تصادفی و پارامترهای ثابت، نتایج ناپایداری ارائه داد، در حالی که آموزش AnoGAN زمان زیادی (بیش از دو ساعت) طول کشید و نتایج محدودی داشت. شبکه‌های مبتنی بر GAN به خاطر مشکلاتی مانند فروپاشی mode (mode collapse) و تولید تنها بخشی از فضای داده‌ی اصلی، به سختی آموزش پذیر هستند [62].

9. به طور مشابه، چندین آزمایش با β -VAE مانند [81] ترتیب کردیم. با این حال، بهترین نتایج با مقدار پیش‌فرض $\beta = 1.0$ مقاله‌ی اصلی ارائه شده بود، به دست آمد. این موضوع چندان غیرمنتظره نبود، چرا که در بازتولید نتایج β -VAE نیز مشکلاتی گزارش شده‌اند [82]. در نهایت، از پیاده‌سازی Deep-SVDD [82] پیش استفاده کردیم که نتایج آن به طور قابل توجهی ضعیفتر از الگوریتم‌های ارائه شده در بخش ۴ بود.

10. برای اختصار، تمام الگوریتم‌های آزمایش شده را در مقاله نیاورده‌ایم و تنها سه مورد با بهترین عملکرد و اصول زیرساختی متفاوت را انتخاب کردیم؛ با این حال، کدها و تنظیمات پارامترهای مورد استفاده در مخزن ما در دسترس هستند. ما نتیجه می‌گیریم که ضعف عملکرد پیش‌بینی در برخی روش‌های استفاده شده، ناشی از فضای ویژگی بسیار بزرگ مجموعه‌داده است. اگرچه استفاده از تکنیک‌های انتخاب ویژگی برای سه مدل برتر عملکرد خوبی داشته است (نگاه کنید به شکل ۳)، اما کارهای آینده روش‌های اضافی تمرکز خواهد داشت. تجزیه‌ی ماتریس غیرمنفی (NMF) [83] امیدبخش است، اما آزمایش‌های اولیه‌ی ما با آن نتایج محدودی داشته‌اند. در آینده، بازنگری در ساختار مجموعه‌های آموزشی و آزمایشی، شامل گراف‌های جدول‌های مسیریابی در شبکه‌ی مش و افزودن روش‌های AD جدید، در دستور کار خواهد بود.

11. نتیجه‌گیری

در دهه‌ی گذشته، روش‌های یادگیری ماشین (ML) رشد چشمگیری داشته‌اند و در حوزه‌های متعددی به کار گرفته شده‌اند. شبکه‌های کامپیوتری نیز از این قاعده مستثنی نیستند و مطالعات متعددی از ML برای شناسایی نفوذ در شبکه استفاده کردند. تشخیص خطأ در شبکه‌های کامپیوتری یکی از کاربردهای جذاب ML است که تاکنون توجه کمی به آن شده، عمدتاً به دلیل نبود مجموعه‌داده‌های در دسترس. در این مقاله، تلاش کردیم این خلاً را با اجرای تشخیص ناهمجارتی برای شناسایی خطأ با استفاده از ML بر کنیم، روش‌های ML انتخاب شده در این مطالعه بر پایه چهار اصل کاملاً متفاوت هستند. نخست، تحلیل مؤلفه‌های اصلی (PCA) است؛ روشی شناخته شده که در صنعت تولید کاربرد گسترده‌ای دارد و بر پایه‌ی نگاشت داده‌ها به زیرفضایی با بعد کاهش‌یافته است که بیشترین واریانس را حفظ می‌کند. دوم، جنگل ایزووله نمونه‌ها عمل می‌کند و نمونه‌هایی را که در تعداد گام‌های کمتری ایزووله می‌شوند، به عنوان ناهمجارت در نظر می‌گیرد. سوم، روش مبتنی بر خوشبندی

روش CBLOF و Local Outlier Factor بر پایه‌ی اصل خوشبندی عمل می‌کنند؛ به طوری که نمونه‌هایی که فاصله‌ی بیشتری از خوشبندی شکل گرفته دارند، به عنوان ناهمجارت در نظر گرفته می‌شوند. نهایت، از AutoEncoder های تغییرپذیر (VAE) استفاده کردیم که بر پایه‌ی مدل‌های شبکه‌ی عصبی عمیق بنا شده‌اند. تمام این روش‌ها در مطالعات پیشین به عنوان گرینه‌هایی مناسب برای تشخیص ناهمجارتی (AD) معرفی شده‌اند.

برخلاف سایر مطالعات موجود در ادبیات، ما مجموعه‌داده‌ای از یک شبکه‌ی عملیاتی واقعی ساخته‌ایم. در این مجموعه‌داده، بازه‌ای را انتخاب کردیم که در آن یک خرابی ناگهانی در دروازه شبکه رخ داده است. این رخداد نادر به ما اجازه داد تا عملکرد روش‌های یادگیری ماشین مورد بررسی را با سنجش تعادل نمونه‌هایی که در بازه‌ی خرابی به عنوان ناهمجارت علمات گذاری شده‌اند، تحلیل کنیم. نمونه‌ها هر ۵ دقیقه جمع‌آوری شده‌اند و شامل ویژگی‌های ترافیکی و غیرترافیکی مانند مصرف CPU، مصرف حافظه و غیره هستند. دوره‌ی آموزشی شامل ۴ هفته و دوره‌ی آزمایشی شامل ۳ روز است. خرابی دروازه به مدت ۱۶ ساعت در میانه‌ی دوره‌ی آزمایشی رخ داده است.

نتایج اصلی به صورت زیر خلاصه می‌شوند:

- در صورت تنظیم مناسب، ناهمجارتی‌های ناشی از خرابی دروازه به خوبی توسط تمام روش‌های یادگیری ماشین شناسایی می‌شوند.
- خارج از بازه‌ی خرابی، چندین جهش ترافیکی نیز به عنوان ناهمجارت علمات گذاری شده‌اند. این جهش‌ها را می‌توان نویز و حاصل الگوهای نامنظم ترافیکی کاربران دانست.
- روش یادگیری عمیق مبتنی بر VAE عملکرد بهتری نسبت به سایر روش‌ها دارد، هرچند با هزینه‌ی محاسباتی بالاتر همراه است.
- در نظر گرفتن ویژگی‌های مرتبط با CPU و حافظه در کنار ویژگی‌های ترافیکی، تعادل نقاط ناهمجارت شناسایی شده در بازه‌ی خرابی دروازه را به طور قابل توجهی افزایش می‌دهد.
- از میان روش‌های انتخاب ویژگی آزمایش شده، میانگین تفاوت مطلق (MAD) و مقدار شپلی (SHAP) (بهترین عملکرد را داشتند). محسابه‌ی ساده‌تری دارد، در حالی که در SHAP در بر کمتری از دلایل شناسایی ناهمجارتی‌ها ارائه دارد.

CRediT authorship contribution statement

Llorenç Cerdà-Alabern: Conceptualization, Investigation, Software, Writing, Dataset gathering. **Gabriel Iuhasz:** Conceptualization, Investigation, Software, Writing. **Gabriele Gemmi:** Investigation, Writing.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Data availability

The dataset is available at the link to Zenodo provided in the paper.

Acknowledgments

This work has received funding through the DiPET CHIST-ERA under grant agreement PCI2019-111850-2; Spanish grant PID2019-106774RB-C21; Romanian DIPET (62652/15.11.2019) project funded via PN 124/2020; and has been partially supported by the EU research project SERRANO (101017168) and hardware resources courtesy of the Romanian Ministry of Research and Innovation UEFISCDI COCO research project PN III-P4-ID-PCE-2020-0407.

References

- [1] V. Chandola, A. Banerjee, V. Kumar, Anomaly detection: A survey, *ACM Comput. Surv.* 41 (3) (2009) 1–58.
- [2] C.C. Aggarwal, *Outlier Analysis*, Springer, 2017.
- [3] M. Ahmed, A.N. Mahmood, J. Hu, A survey of network anomaly detection techniques, *J. Netw. Comput. Appl.* 60 (2016) 19–31.
- [4] D.P. Kumar, T. Amgoth, C.S.R. Annavarapu, Machine learning algorithms for wireless sensor networks: A survey, *Inf. Fusion* 49 (2019) 1–25.
- [5] M. Mohri, A. Rostamizadeh, A. Talwalkar, *Foundations of Machine Learning*, MIT Press, 2018.
- [6] K.P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.
- [7] L.N. Tidjón, M. Frappier, A. Mammar, Intrusion detection systems: A cross-domain overview, *IEEE Commun. Surv. Tutor.* 21 (4) (2019) 3639–3681.
- [8] G. Fernandes, J.J. Rodrigues, L.F. Carvalho, J.F. Al-Muhtadi, M.L. Proença, A comprehensive survey on network anomaly detection, *Telecommun. Syst.* 70 (3) (2019) 447–489.
- [9] D. Vega, R. Baig, L. Cerdà-Alabern, E. Medina, R. Meseguer, L. Navarro, A technological overview of the guifi.net community network, *Comput. Netw.* 9 (2) (2015) 260–278, <http://dx.doi.org/10.1016/j.comnet.2015.09.023>.
- [10] Y. Ben David, *Connecting the Last Billion* (Ph.D. thesis), UC Berkeley, 2015.
- [11] Guifi.net, Open, free and neutral network internet for everybody, 2021, <http://guifi.net/en>. (Accessed 13 January 2021).
- [12] L. Cerdà-Alabern, R. Baig, L. Navarro, On the guifi.net community network economics, *Comput. Netw.* 168 (2020) 107067.
- [13] GuifiSants, Xarxa oberta, lliure i neutral del barri de sants, 2021, <http://sants.guifi.net/>. (Accessed January 2021).
- [14] J. Camacho, A. Pérez-Villegas, P. Garcíá a Teodoro, G. Maciá-Fernández, PCA-based multivariate statistical network monitoring for anomaly detection, *Comput. Secur.* 59 (2016) 118–137.
- [15] D.H. Hoang, H.D. Nguyen, A PCA-based method for IoT network traffic anomaly detection, in: 2018 20th International Conference on Advanced Communication Technology, ICACT, IEEE, 2018, pp. 381–386.
- [16] I.K. Savvas, A.V. Chernov, M.A. Butakova, C. Chaikalis, Increasing the quality and performance of N-dimensional point anomaly detection in traffic using PCA and DBSCAN, in: 2018 26th Telecommunications Forum, TELFOR, IEEE, 2018, pp. 1–4.
- [17] Munin networked resource monitoring tool, <http://munin-monitoring.org>.
- [18] Nagios, The Industry Standard In IT Infrastructure Monitoring, <https://www.nagios.org>.
- [19] L. Cerdà-Alabern, Dataset for Anomaly Detection in a Production Wireless Mesh Community Network, Zenodo, 2022, <http://dx.doi.org/10.5281/zenodo.6169917>.
- [20] V. Hodge, J. Austin, A survey of outlier detection methodologies, *Artif. Intell. Rev.* 22 (2) (2004) 85–126.
- [21] S. Northcutt, J. Novak, *Network Intrusion Detection*, Sams Publishing, 2002.
- [22] A. Lakhina, K. Papagiannaki, M. Crovella, C. Diot, E.D. Kolaczyk, N. Taft, Structural analysis of network traffic flows, in: Proceedings of the Joint International Conference on Measurement and Modeling of Computer Systems, 2004 pp. 61–72.
- [23] Z.R. Zaidi, S. Hakami, T. Moors, B. Landfeldt, Detection and identification of anomalies in wireless mesh networks using principal component analysis (PCA), *J. Interconnect. Netw.* 10 (04) (2009) 517–534.
- [24] Z.R. Zaidi, S. Hakami, B. Landfeldt, T. Moors, Real-time detection of traffic anomalies in wireless mesh networks, *Wirel. Netw.* 16 (6) (2010) 1675–1689.
- [25] C. Pascoal, M.R. De Oliveira, R. Valadas, P. Filzmoser, P. Salvador, A. Pacheco, Robust feature selection and robust PCA for internet traffic anomaly detection, in: 2012 Proceedings IEEE Infocom, IEEE, 2012, pp. 1755–1763.
- [26] H. Ringberg, A. Soule, J. Rexford, C. Diot, Sensitivity of PCA for traffic anomaly detection, in: Proceedings of the 2007 ACM SIGMETRICS International Conference on Measurement and Modeling of Computer Systems, 2007 pp. 109–120.
- [27] N.L.D. Khoa, T. Babiae, S. Chawla, Z. Zaidi, Network anomaly detection using a commute distance based approach, in: 2010 IEEE International Conference on Data Mining Workshops, IEEE, 2010, pp. 943–950.
- [28] A.B. Nassif, M.A. Talib, Q. Nasir, F.M. Dakalbab, Machine learning for anomaly detection: A systematic review, *IEEE Access* 9 (2021) 78658–78700, <http://dx.doi.org/10.1109/ACCESS.2021.3083060>.
- [29] S. Goldstein, A comparative evaluation of unsupervised anomaly detection algorithms for multivariate data, *PLoS One* 11 (4) (2016) 1–31, <http://dx.doi.org/10.1371/journal.pone.0152173>.
- [30] M. Ahmed, A.N. Mahmood, Novel approach for network traffic pattern analysis using clustering-based collective anomaly detection, *Ann. Data Sci.* 2 (2015) 111–130.
- [31] X. Chun-Hui, S. Chen, B. Cong-Xiao, L. Xing, Anomaly detection in network management system based on isolation forest, in: 2018 4th Annual International Conference on Network and Information Systems for Computers, ICNISC, 2018, pp. 56–60, <http://dx.doi.org/10.1109/ICNISC.2018.00019>.
- [32] G. Pang, C. Shen, L. Cao, A.V.D. Hengel, Deep learning for anomaly detection: A review, *ACM Comput. Surv.* 54 (2) (2021) <http://dx.doi.org/10.1145/3439950>.
- [33] N. Takeishi, Y. Kawahara, On anomaly interpretation via Shapley values, 2020, <arXiv:2004.04464>.
- [34] L. Antwarg, R.M. Miller, B. Shapira, L. Rokach, Explaining anomalies detected by autoencoders using Shapley additive explanations, *Expert Syst. Appl.* 186 (2021) 115736, <http://dx.doi.org/10.1016/j.eswa.2021.115736>.
- [35] C. Zhou, R.C. Paffenroth, Anomaly detection with robust deep autoencoders, in: Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD ’17, Association for Computing Machinery, New York, NY, USA, 2017, pp. 665–674, <http://dx.doi.org/10.1145/3097983.3098052>.
- [36] D.P. Kingma, M. Welling, Auto-encoding variational Bayes, 2014, <arXiv:1312.6114>.
- [37] M. Moulay, R.G. Leiva, V. Mancuso, P.J.R. Maroni, A.F. Anta, Ttrees: Automated classification of causes of network anomalies with little data, in: 2021 IEEE 22nd International Symposium on a World of Wireless, Mobile and Multimedia Networks, WoWMoM, IEEE, 2021, pp. 199–208.
- [38] K. Sequeira, M. Zaki, ADMIT: Anomaly-based data mining for intrusions, in: Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD ’02, Association for Computing Machinery, New York, NY, USA, 2002, pp. 386–395, <http://dx.doi.org/10.1145/775047.775103>.
- [39] Y.F. Zhang, Z.Y. Xiong, X.Q. Wang, Distributed intrusion detection based on clustering, in: 2005 International Conference on Machine Learning and Cybernetics, vol. 4, 2005, pp. 2379–2383 Vol. 4, <http://dx.doi.org/10.1109/ICMLC.2005.1527342>.
- [40] M.H. Bhuyan, D.K. Bhattacharyya, J.K. Kalita, An effective unsupervised network anomaly detection method, in: Proceedings of the International Conference on Advances in Computing, Communications and Informatics, ICACCI ’12, Association for Computing Machinery, New York, NY, USA, 2012, pp. 533–539, <http://dx.doi.org/10.1145/2345396.2345484>.
- [41] N. Hu, Z. Tian, H. Lu, X. Du, M. Guizani, A multiple-kernel clustering based intrusion detection scheme for 5G and IoT networks, *Int. J. Mach. Learn. Cybern.* 12 (2021) <http://dx.doi.org/10.1007/s13042-020-01253-w>.
- [42] M.E. Otey, A. Ghoting, S. Parthasarathy, Fast distributed outlier detection in mixed-attribute data sets, *Data Min. Knowl. Discov.* 12 (2–3) (2006) 203–228, <http://dx.doi.org/10.1007/s10618-005-0014-6>.
- [43] M. Bhuyan, D.K. Bhattacharyya, J. Kalita, A multi-step outlier-based anomaly detection approach to network-wide traffic, *Inform. Sci.* 348 (2016) <http://dx.doi.org/10.1016/j.ins.2016.02.023>.
- [44] P. Casas, J. Mazel, P. Owezarski, Unsupervised network intrusion detection systems: Detecting the unknown without knowledge, *Comput. Commun.* 35 (7) (2012) 772–783, <http://dx.doi.org/10.1016/j.comcom.2012.01.016>.
- [45] O. Iraqi, H. El Bakkali, Application-level unsupervised outlier-based intrusion detection and prevention, *Secur. Commun. Netw.* 2019 (2019) 1–13, <http://dx.doi.org/10.1155/2019/8368473>.
- [46] M. Khan, Rule based network intrusion detection using genetic algorithm, *Int. J. Comput. Appl.* 18 (2011) 26–29, <http://dx.doi.org/10.5120/2303-2914>.
- [47] H. Alsaeedi, R. Almuttairi, O. Ucan, O. Bayat, An adapting soft computing model for intrusion detection system, *Comput. Intell.* 01 (2021) <http://dx.doi.org/10.1111/coin.12433>.
- [48] A. Shenfield, D. Day, A. Ayesh, Intelligent intrusion detection systems using artificial neural networks, *ICT Express* 4 (2) (2018) 95–99, <http://dx.doi.org/10.1016/j.icte.2018.04.003>, SI on Artificial Intelligence and Machine Learning.
- [49] C.F. Alcalá, S.J. Qin, Analysis and generalization of fault diagnosis methods for process monitoring, *J. Process Control* 21 (3) (2011) 322–330.
- [50] P. Miller, R.E. Swanson, C.E. Heckler, Contribution plots: A missing link in multivariate quality control, *Appl. Math. Comput. Sci.* 8 (4) (1998) 775–792.
- [51] C.C. Aggarwal, S. Sathe, Theoretical foundations and algorithms for outlier ensembles, *SIGKDD Explor. Newsl.* 17 (1) (2015) 24–47, <http://dx.doi.org/10.1145/2830544.2830549>.
- [52] C.C. Aggarwal, Outlier ensembles: Position paper, *SIGKDD Explor. Newsl.* 14 (2) (2013) 49–58, <http://dx.doi.org/10.1145/2481244.2481252>.
- [53] F.T. Liu, K.M. Ting, Z.H. Zhou, Isolation-based anomaly detection, *ACM Trans. Knowl. Discov. Data* 6 (1) (2012) <http://dx.doi.org/10.1145/2133360.2133363>.
- [54] F.T. Liu, K.M. Ting, Z.H. Zhou, Isolation forest, in: 2008 Eighth IEEE International Conference on Data Mining, 2008, pp. 413–422, <http://dx.doi.org/10.1109/ICDM.2008.17>.
- [55] Z. He, X. Xu, S. Deng, Discovering cluster-based local outliers, *Pattern Recognit. Lett.* 24 (9) (2003) 1641–1650, [http://dx.doi.org/10.1016/S0167-8655\(03\)00003-5](http://dx.doi.org/10.1016/S0167-8655(03)00003-5).
- [56] M.M. Breunig, H.P. Kriegel, R.T. Ng, J. Sander, LOF: Identifying density-based local outliers, *SIGMOD Rec.* 29 (2) (2000) 93–104, <http://dx.doi.org/10.1145/335191.335388>.
- [57] R. Zheng, J. Gu, Anomaly detection for power system forecasting under data corruption based on variational auto-encoder, in: 8th Renewable Power Generation Conference, RPG 2019, 2019, pp. 1–6, <http://dx.doi.org/10.1049/cp.2019.0461>.
- [58] R. Yao, C. Liu, L. Zhang, P. Peng, Unsupervised anomaly detection using variational auto-encoder based feature extraction, in: 2019 IEEE International Conference on Prognostics and Health Management, ICPHM, 2019, pp. 1–7, <http://dx.doi.org/10.1109/ICPHM.2019.8819434>.
- [59] Y. Aizenbud, O. Lindenbaum, Y. Kluger, Probabilistic robust autoencoders for anomaly detection, 2021, <arXiv:2110.00494>.

- [60] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, R. Salakhutdinov, Dropout: A simple way to prevent neural networks from overfitting, *J. Mach. Learn. Res.* 15 (56) (2014) 1929–1958, <http://jmlr.org/papers/v15/srivastava14a.html>.
- [61] C.P. Burgess, I. Higgins, A. Pal, L. Matthey, N. Watters, G. Desjardins, A. Lerchner, Understanding disentangling in β -VAE, *CoRR* (2018) arXiv:1804.03599.
- [62] L. Zhou, W. Deng, X. Wu, Unsupervised anomaly localization using VAE and beta-VAE, 2020, <http://dx.doi.org/10.48550/ARXIV.2005.10686>.
- [63] J. Cai, J. Luo, S. Wang, S. Yang, Feature selection in machine learning: A new perspective, *Neurocomputing* 300 (2018) 70–79, <http://dx.doi.org/10.1016/j.neucom.2017.11.077>.
- [64] C. Suman, S. Tripathy, S. Saha, Building an effective intrusion detection system using unsupervised feature selection in multi-objective optimization framework, 2019, arXiv preprint arXiv:1905.06562.
- [65] A.J. Ferreira, M.A.T. Figueiredo, Efficient feature selection filters for high-dimensional data, *Pattern Recognit. Lett.* 33 (13) (2012) 1794–1804, <http://dx.doi.org/10.1016/j.patrec.2012.05.019>.
- [66] L.S. Shapley, 17. A value for n-person games, in: H.W. Kuhn, A.W. Tucker (Eds.), *Contributions to the Theory of Games (AM-28)*, vol. II, Princeton University Press, 2016, pp. 307–318, <http://dx.doi.org/10.1515/9781400881970-018>.
- [67] C. Molnar, *Interpretable Machine Learning*, Independently published, 2022.
- [68] OpenWrt Project, OpenWrt project: Welcome to the OpenWrt project, 2021, <https://openwrt.org/>. (Accessed January 2021).
- [69] BMX6 mesh networking protocol, <http://bmx6.net>. (Accessed January 2021).
- [70] L. Cerdà-Alabern, A. Neumann, L. Maccari, Experimental evaluation of BMX6 routing metrics in a 802.11an wireless-community mesh network, in: 2015 3rd International Conference on Future Internet of Things and Cloud, 2015 pp. 770–775.
- [71] GuifiSants, qMp Sants-UPC, 2021, <http://dsg.ac.upc.edu/qmpsu>. (Accessed January 2021).
- [72] L. Cerdà-Alabern, A. Neumann, P. Escrich, Experimental evaluation of a wireless community mesh network, in: The 16th ACM International Conference on Modeling, Analysis and Simulation of Wireless and Mobile Systems, MSWiM’13, ACM, Barcelona, Spain, 2013.
- [73] F. Pedregosa, et al., Scikit-learn: Machine learning in Python, *J. Mach. Learn. Res.* 12 (2011) 2825–2830.
- [74] Y. Zhao, Z. Nasrullah, Z. Li, Pyod: A Python toolbox for scalable outlier detection, *J. Mach. Learn. Res.* 20 (96) (2019) 1–7, <http://jmlr.org/papers/v20/19-011.html>.
- [75] A. Mahfouz, A. Abuhussein, D. Venugopal, S. Shiva, Ensemble classifiers for network intrusion detection using a novel network attack dataset, *Future Internet* 12 (11) (2020) <http://dx.doi.org/10.3390/fi12110180>.
- [76] S.M. Lundberg, S.I. Lee, A unified approach to interpreting model predictions, in: I. Guyon, U.V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, R. Garnett (Eds.), *Advances in Neural Information Processing Systems 30*, Curran Associates, Inc., 2017, pp. 4765–4774.
- [77] L. McInnes, J. Healy, S. Astels, Hdbscan: Hierarchical density based clustering, *J. Open Source Softw.* 2 (11) (2017) 205, <http://dx.doi.org/10.21105/joss.00205>.
- [78] M. Ester, H.P. Kriegel, J. Sander, X. Xu, A density-based algorithm for discovering clusters in large spatial databases with noise, in: *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, KDD ’96*, AAAI Press, 1996, pp. 226–231.
- [79] H. Zenati, M. Romain, C.S. Foo, B. Lecouat, V.R. Chandrasekhar, Adversarially learned anomaly detection, 2018, <http://dx.doi.org/10.48550/ARXIV.1812.02288>.
- [80] T. Schlegl, P. Seeböck, S.M. Waldstein, U. Schmidt-Erfurth, G. Langs, Unsupervised anomaly detection with generative adversarial networks to guide marker discovery, 2017, <http://dx.doi.org/10.48550/ARXIV.1703.05921>.
- [81] M. Fil, M. Mesinovic, M. Morris, J. Wildberger, Beta-VAE reproducibility: Challenges and extensions, 2021, <http://dx.doi.org/10.48550/ARXIV.2112.14278>, <https://arxiv.org/abs/2112.14278>.
- [82] P. Liznerski, L. Ruff, R.A. Vandermeulen, B.J. Franks, M. Kloft, K.R. Müller, Explainable deep one-class classification, 2020, <http://dx.doi.org/10.48550/ARXIV.2007.01760>.
- [83] H. Alshammari, O. Ghorbel, M. Aseeri, M. Abid, Non-negative matrix factorization (NMF) for outlier detection in wireless sensor networks, in: 2018 14th International Wireless Communications & Mobile Computing Conference, IWCMC, 2018, pp. 506–511, <http://dx.doi.org/10.1109/IWCMC.2018.8450421>.